

**Bachelorarbeit zur Erlangung des Grades
Bachelor of Science
im Studiengang Wirtschaftsinformatik**

Funktionsweise, Anwendungen und Risiken von Texterzeugungsmodellen am Beispiel von GPT

Jonas Bevernis

Matrikel 16859

Erstgutachter: Prof. Dr. Thomas Wengerek

Zweitgutachter: Prof. Dr. Gero Szepannek

28.07.2021

Hochschule Stralsund

Fakultät für Wirtschaft

Inhaltsverzeichnis

1. Einleitung.....	3
2. Funktionsweise.....	4
2.1. Theoretische Erklärung grundlegender Konzepte.....	4
2.2. OpenAI GPT	7
2.2.1. Funktionsweise von GPT	10
2.2.2. Programmbeispiele mit GPT.....	18
2.2.3. Schlussfolgerungen aus den Programmbeispielen.....	31
3. Anwendungsmöglichkeiten	34
3.1 Anwendungsmöglichkeit 1: Automatische Quellcode Generierung	36
3.2 Anwendungsmöglichkeit 2: Automatische Erzeugung von Nachrichtenartikeln	40
4. Risiken.....	43
4.1 Risiken bei Anwendungsmöglichkeit 1: Automatische Quellcode Generierung	44
4.2 Risiken bei Anwendungsmöglichkeit 2: Automatische Erzeugung von Nachrichtenartikeln.....	48
5. Fazit	52
Abbildungsverzeichnis.....	54
Tabellenverzeichnis	55
Literaturverzeichnis	56

1. Einleitung

Texterzeugungsmodelle, oft auch als „Natural language processing“-Modelle bezeichnet, sind Machine-Learning-Modelle, welche für das Verarbeiten und Ausgeben von Text trainiert wurden. Diese Art der Machine-Learning-Modelle erfreut sich momentan, aufgrund der stark voranschreitenden Entwicklung, hoher Beliebtheit. Zu diesen Modellen gehören zum Beispiel das von Google entwickelte „BERT“-Modell („Bidirectional Encoder Representations from Transformers“) oder GPT-3 („Generative Pre-trained Transformer“) von OpenAI, zu den mächtigsten Modellen. Texterzeugungsmodelle bieten ein sehr breites Anwendungsfeld, welches von der Nutzung zum Schreiben von Fließtexten bis hin zur Verwendung als Assistenzsystem beim Schreiben von Quellcode reicht. Aus dieser Vielzahl an Anwendungsbereichen ergeben sich allerdings auch eine Menge an Risiken wie zum Beispiel der Missbrauch der Technologie. All das wird mithilfe einer komplexen Machine-Learning-Struktur erreicht.

In dieser Arbeit sollen diese Aspekte der Funktionsweise, Anwendungen und Risiken dieser Modelle herausgearbeitet werden. Dabei sollen die GPT-Modelle als, sich durch die Arbeit ziehendes, Beispiel dienen. Aufgrund der hohen Komplexität des Themas ist es, im Umfang dieser Arbeit, kaum möglich alle Aspekte bis ins Detail herauszuarbeiten. Vielmehr soll das Ziel der Arbeit darin liegen einen Überblick zu geben, welche ausreichend ins Detail geht, um ein Verständnis von Texterzeugungsmodellen in ihrer Gesamtheit zu erhalten. Dabei wird sich, insbesondere im hoch komplexen Bereich der Funktionsweise, zwecks Einschränkung des Umfangs, Großteiles auf die GPT-Reihe beschränkt.

Für diese Arbeit soll speziell die GPT-Reihe als Beispiel dienen. Die Wahl von GPT über anderes Modell wie „BERT“ hat verschiedene Gründe. Auf der einen Seite ist GPT auf dem neusten Stand der Technik und bietet ein breites Anwendungsfeld. Dabei kommt GPT, insbesondere im Fall von GPT-3, mit vergleichsweise kleinen Datensätzen aus. Auf der anderen Seite entstand um GPT, bei der Veröffentlichung von GPT-3, eine große Menge an Aufmerksamkeit, wodurch auch mein Interesse geweckt wurde. Dies führte außerdem dazu, dass es im Internet eine Menge Informationen zur GPT-Reihe gibt. Alles in allem standen die spezifischen Vorteile von GPT nicht im Mittelpunkt bei der Entscheidung GPT als Beispiel zu wählen. Vielmehr war es einfach eine, durch persönliches Interesse gesteuerte, Entscheidung. Am Ende wäre die Untersuchung von Texterzeugungsmodellen auch anhand eines anderen Modells wie „BERT“ möglich gewesen.

Zur Erreichung des Ziels wird zuerst die Funktionsweise von GPT untersucht. Dabei ist es, um einen guten Überblick zu erhalten, wichtig, dass nicht nur die theoretische, sondern, mithilfe einiger Experimente, auch die praktische Funktionsweise untersucht und dargestellt wird. Nachdem die Funktionsweise von Texterzeugungsmodellen am Beispiel von GPT dargestellt wurde, sollen die Anwendungsmöglichkeiten solcher Modelle untersucht werden. Um auch hier den Umfang einzuschränken, sollen hier, neben einer kurzen allgemeinen Beschreibung der Anwendungsfälle, zwei spezielle Anwendungsfälle gezielt untersucht werden. Im letzten großen Kapitel werden schließlich die Risiken von Texterzeugungsmodellen untersucht. Hier sollen vor allem die Risiken der zwei zuvor beschriebenen Anwendungsmöglichkeiten herausgearbeitet werden.

2. Funktionsweise

2.1. Theoretische Erklärung grundlegender Konzepte

Neuronale Netze im Allgemeinen sind ein sehr komplexes und umfangreiches Thema, eine genaue ins Detail gehende Erklärung neuronaler Netze im Allgemeinen würde den Rahmen dieser Arbeit sprengen. Stattdessen werden in diesem Kapitel einige grundlegende Begriffe erläutert, die wichtig für die Funktionsweise von Texterzeugungsmodellen sind und benötigt werden, um die detailreichere Erklärung von GPT im Kapitel 2.2.1. zu verstehen.

Nichtsdestotrotz ist zumindest eine grundlegende Erklärung neuronaler Netze wichtig, um die später folgenden Konzepte zu verstehen.

Bei neuronalen Netzen kann man unter anderem zwischen den zwei Folgenden unterscheiden: Vorwärts-gerichtete neuronale Netze, auch Feed-forward neural network genannt, und rückgekoppelte neuronale Netze, welche auch als recurrent neural network bezeichnet werden. Der grundsätzliche Aufbau beider Arten ist ähnlich und in Abbildung 1 zu sehen. Der Aufbau orientiert sich grob am Aufbau eines biologischen Gehirns.




Abbildung 1: Vereinfachte Darstellung eines künstlichen neuronalen Netzes [1]

Ein künstliches neuronales Netz besteht, wie auch in der Abbildung zu sehen ist, aus einer Vielzahl an Neuronen, welche, neben den Eingabe- und Ausgabe-Neuronen, in Schichten eingeteilt sind. In der Abbildung sind beispielhaft zwei Schichten von Neuronen dargestellt, im echten Einsatz sind es meist allerdings deutlich mehr. Eine wichtige Eigenschaft der Neuronen ist ihre Verknüpfung untereinander mit verschiedenen Gewichtungen. Der Unterschied zwischen vorwärts-gerichteten neuronalen Netzen und rückgekoppelten neuronalen Netzen besteht in der Flussrichtung der Informationen, während die Neuronen von vorwärts-gerichteten neuronalen Netzen Informationen nur in eine Richtung, in Richtung der Ausgabe-Neuronen, weitergeben, nutzen rückgekoppelten neuronalen Netzen, Neuronen, die es ermöglichen mittels einer Rückkopplung Informationen auch an die vorherige Schicht

weiterzugeben. Diese Rückkopplung ist in der Abbildung durch den Blauen Pfeil dargestellt und existiert in einem vorwärts-gerichteten neuronalen Netz nicht. [1]

Ein wichtiger Bestandteil bei der Nutzung neuronaler Netze ist das Training. Dabei werden die Netze einer großen Menge Daten aus einem Datensatz an die gewünschte Aufgabenstellung angepasst. Beim Training gibt es in erster Linie drei verschiedene Ansätze.

1. Überwachtes Lernen bzw. Supervised Machine Learning. Bei dieser Methode sind die Daten im Datensatz bekannt und müssen, vor dem Training des neuronalen Netzes, gekennzeichnet werden. Diese Kennzeichnung kann zum Beispiel eine Sortierung der Daten in verschiedene Gruppen sein. Diese Methode bietet den Vorteil, dass ein vergleichsweise gezielter Lernvorgang im Modell durchgeführt werden kann. Allerdings ist eine, besonders bei sehr großen Datensätzen, aufwendige Vorbereitung der Daten nötig.

2. Unüberwachtes Lernen bzw. Unsupervised Machine Learning. Wenn im Vorhinein keine Kennzeichnung der Daten im Datensatz stattfindet, wird dies als unüberwachtes Lernen bezeichnet. Ein gezieltes Training des Modelles ist hier nicht das Ziel, vielmehr soll hier das Modell eigenständig die Datenstrukturen erkennen und selbst interpretieren. Ein großer Vorteil dieses Ansatzes ist, dass keine aufwendige Kennzeichnung der Daten notwendig ist und dadurch auch sehr große Datensätze leicht verwendet werden können.

3. Verstärkendes Lernen bzw. Reinforcement Machine Learning. Dieser Ansatz des Trainings unterscheidet sich stark von den anderen beiden. Hier wird kein klassischer Datensatz für das Training genutzt, vielmehr interagiert das Modell mit seiner Umgebung und wird für gewünschte Abläufe belohnt. Der Ablauf ist in etwa mit dem Training eines Hundes zu vergleichen. Ein ausführlicheres Beispiel für dies Art des Trainings findet sich im Folgenden, Kapitel 2.2 „OpenAI GPT“. [1]

Für das Training eines Texterzeugungsmodells sind vor allem die Ansätze des überwachten- und unüberwachten Lernens interessant, während verstärkendes Lernen für diesen Aufgabenbereich eine untergeordnete Rolle spielt.

Für den Aufgabenbereich der Texterzeugung werden typischerweise sogenannte „sequences to sequence“, kurz seq2seq, Modelle verwendet. „sequences to sequence“ ist ein Überbegriff für verschiedene Machine-Learning-Modell Strukturen, dessen Zweck es ist eine eingegebene Sequenz in eine andere Sequenz zu überführen. Ein typischer Anwendungsfall wäre zum Beispiel die Übersetzung eines englischen Satzes ins deutsche. Zu der Kategorie der seq2seq Modelle gehören verschiedene unterschiedliche Modell-Strukturen, eines der bekanntesten ist des Sogenannten „Long Short-Term Memory“-Modell, kurz LSTM. Die grundlegende LSTM Struktur wurde bereits im Jahr 1997 von S. Hochreiter und J. Schmidhuber in ihrer Arbeit „Long Short-Term Memory“ vorgestellt, dabei handelt es sich um eine spezielle Art der Anordnung von Daten einer Sequenz. [2] Die spezielle Anwendung der LSTM Struktur auf den Bereich der Texterzeugungsmodelle, sowie der „sequences to sequence“ Begriff, wurde allerdings erst 2014 in der Arbeit „Sequence to Sequence Learning with Neural Networks“ von Google Mitarbeitern vorgestellt. Wird heute, im Kontext der künstlichen Intelligenz, von einem LSTM gesprochen ist in der Regel das 2014 vorgestellte LSTM-Maschine-Learning-Modell gemeint. Ein LSTM-Modell funktioniert grundlegend wie folgt: Ein LSTM kann in den Bereich der rückgekoppelten neuronalen Netze eingeordnet werden. Dabei nutzt ein LSTM-Modell eine zweigeteiltem Encoder-Decoder Struktur. So besteht ein LSTM-Modell eigentlich aus zwei verschiedenen rückgekoppelten neuronalen Netzen, eins im Encoder und

2. Funktionsweise

eins im Decoder, diese Struktur bietet die Möglichkeit den Input und den Output einzeln, durch zwei unterschiedliche neuronale Netze, zu bearbeiten, während in vielen klassischen Modellen Input und Output von einem einzigen neuronalen Netz bearbeitet werden. Der Encoder bearbeitet bei dieser Struktur den Input und kodiert diesen (wie der Name schon sagt). Der Decoder entschlüsselt die Daten des Encoders wieder und sorgt für die Ausgabe. Die ursprüngliche LSTM-Struktur, die 1997 vorgestellt wurde und dem Modell seinen Namen gibt, wird im Encoder genutzt um die Eingabesequenz in eine, für das Modell verständliche, Struktur, zu überführen. Im Decoder wird die LSTM-Struktur dann genutzt, um diese Daten wieder in eine für Menschen verständliche Sequenz zu übersetzen. [2]

Zusammengefasst verbindet ein LSTM-Modell die 1997 vorgestellte LSTM-Struktur mit modernen Technologien wie dem rückgekoppelten neuronalen Netz sowie einer zweigeteilten Encoder-Decoder Struktur, um ein effizientes „sequences to sequence“-Modell zu erzeugen.

In der ursprünglichen Arbeit von 2014, sollte das Modell in erster Linie Übersetzungsaufgaben zu lösen. Was das Modell mit guten Ergebnissen meisterte. [2] Seit dem wurden LSTM-Modelle allerdings auch erfolgreich für eine Vielzahl anderer Aufgaben im Bereich der Texterzeugungsmodelle verwendet und in verschiedenen Hinsichten erweitert. LSTM-Modelle stellen damit eine der klassischen technischen Umsetzungen für Texterzeugungsmodelle dar, die mittlerweile allerdings an vielen Stellen von neueren Modellen abgelöst wurden.

2.2. OpenAI GPT

OpenAI wurde im Dezember 2015 in San Francisco, von dem Programmierer Sam Altman und Elon Musk sowie weiteren Investoren als Non-Profit gegründet. [3] Elon Musk, der aufgrund seiner Bekanntheit, durch seine anderen Firmen wie SpaceX und Tesla anfangs Blicke auf OpenAI zog, hat den Vorstand allerdings seitdem, aufgrund eines möglichen Interessenkonfliktes, verlassen. [4] Laut eigener Aussage sicherte sich die Firma bei ihrer Gründung etwa eine Milliarde US-Dollar an Investment.

OpenAI beschreibt ihren Auftrag selbst so: „Unsere Mission ist es sicherzustellen, dass künstliche Intelligenz der gesamten Menschheit zugutekommt.“ [5] (eigene Übersetzung). Um dieses Ziel zu erreichen hat OpenAI einige Regeln aufgestellt, an die sich die Firma halten will:

1. Aller Einfluss den OpenAI über die Entwicklung von KI erhält soll dem Vorteil aller dienen, dazu müssen Interessenkonflikte insbesondere der Angestellten und Investoren vermieden werden.
2. Das Ziel von OpenAI, neben der Entwicklung von KI-Systemen, ist insbesondere die langfristige Sicherheit dieser Systeme und das Vorantreiben der Forschung zu sicheren KI-Systemen.
3. Um die Sicherheit von KI-Systemen gewährleisten zu können, ist es wichtig, dass OpenAI immer auf dem neusten Stand der KI-Forschung ist. Es ist ihr Ziel diese Forschung anzuführen.
4. Um ihre Ziele zu erreichen will OpenAI mit anderen kooperieren und den Großteil ihrer Forschung der Öffentlichkeit zur Verfügung stellen. [6]

Neben der GPT-Reihe, um die es später in erster Linie gehen soll, hat OpenAI auch eine Vielzahl anderer verschiedener Modelle entwickelt und Forschungspapiere veröffentlicht. So war ihre erste Veröffentlichung, etwa ein halbes Jahr nach der Gründung, zum Beispiel „OpenAI Gym“, ein Toolkit, das dabei helfen soll, verschiedene „reinforcement learning“ Algorithmen zu vergleichen [7]. „reinforcement learning“ bzw. „Bestärkendes Lernen“ ist eine Methode des maschinellen Lernens bei der das Modell durch Belohnungen positiver oder auch negativer Art lernt, sein Ziel bestmöglich zu erreichen. Soll das Modell zum Beispiel Lernen Pong zu spielen könnte es einen positiven Impuls geben, wenn ein Punkt gemacht wird und einen negativen Impuls, wenn der Gegner einen Punkt macht. Die weitere Forschung zum Thema „reinforcement learning“ zeigte sich im OpenAI Five Projekt, einer der größten Erfolge von OpenAI zu dem Zeitpunkt. Bereits im Jahr 2017 gewinnt ihr „reinforcement learning“ Model das erste Mal ein 1 gegen 1 im Spiel Dota 2 gegen einen der weltweit besten Spieler. Daraus entwickelt sich bis 2019 ein Team aus 5 KIs, dass in diesem Jahr das derzeitige Weltmeisterteam „OG“ in zwei aufeinanderfolgenden Spielen besiegt. [8] Um diesen Erfolg einordnen zu können, ist es wichtig die Komplexität eines Spiels wie Dota 2 zu verstehen. Neben den Wechselwirkungen zwischen Bewegung, einsetzbaren Fähigkeiten sowie kaufbaren Gegenständen mussten die KIs den Teamaspekt des Spiels meistern, um die Stärken der 5 Spielfiguren zu kombinieren. Nur so war ein Sieg möglich. OpenAI Five holte nicht nur OpenAI auch für eine breitere Öffentlichkeit ins Rampenlicht, sondern zeigte auch, wie mächtig „reinforcement learning“ Modelle sein können, wenn es um das Erlernen komplexer Zusammenhänge geht.

Neben OpenAI Five ist die GPT-Reihe wohl eine der öffentlichkeitwirksamsten und für das Thema dieser Arbeit interessantesten KI-Modelle an denen OpenAI arbeitet. GPT steht für „Generative Pre-trained Transformer“, die Reihe umfasst 3 Modelle:

GPT: Die erste Version von GPT wurde Juni 2018 veröffentlicht und stellte den anfänglichen Versuch von OpenAI dar, die zu dem Zeitpunkt neuen Transformer-Modelle mit der Methodik des „Semi-supervised training“ zu verbinden (eine genauere Erklärung dieser befindet sich Konzepte findet sich im Kapitel 2.2.2, da diese den Rahmen der Einleitung sprengen würde). Die grundsätzliche Idee ist dabei, das Modell mithilfe eines sehr großen Datensatzes unüberwacht zu trainieren und danach, mittels eines viel kleineren Datensatzes per überwachtem Lernen auf einen bestimmten Aufgabenbereich zu feintunen. So sollen die Vor- und Nachteile der beiden Herangehensweise ausgeglichen werden. Die erste Version von GPT stellte in erster Linie einen Proof of Concept dar, übertraf allerdings laut von OpenAI durchgeführten Tests bereits andere Systeme, die auf dem letzten Stand der Technik waren. Durch den relativen Erfolg von GPT setzte sich das Team einige Ziele:

1. Vergrößerung des Datensatzes. GPT wurde mithilfe von beschränkter Hardware und einem vergleichsweise kleinen Datensatz von etwa 5GB Text trainiert.
2. Verbesserung des Finetunings.
3. Genauere Forschung zum Konzept von „generative pre-training“ [9]

GPT-2: Am 14 Februar 2019 veröffentlicht OpenAI ihre weiterführende Forschung sowie die von ihnen mit GPT-2 erzielten Ergebnisse, das Modell selbst wird zu diesem Zeitpunkt allerdings nicht veröffentlicht. Mit Bezug auf ihre 2. Firmenregel wird nur eine deutlich kleinere Version des Modells veröffentlicht. Sie befürchten Missbrauch des Modells bei vollständiger Veröffentlichung dessen und regen Regierungen dazu an, die weitere KI-Entwicklung im Auge zu behalten. [10] Trotz allem entscheidet sich OpenAI Anfang November 2019 das vollständige Modell zu veröffentlichen. [11] Dieses Modell stellt eine direkte Überarbeitung des Vorgängers GPT dar, bei der in erster Linie der Datensatz massiv vergrößert wurde. Für GPT-2 wurde der Datensatz sowie die Menge an Parametern mehr als verzehnfacht. Dabei bietet das Modell, selbst mit wenig Finetuning, eine bessere Leistung als alle anderen Texterzeugungsmodelle mit denen OpenAI sich vergleicht. [10]

GPT-3: Version 3 ist die neueste der GPT-Reihe, die Mitte 2020 vorgestellt wurde. Wie schon beim Sprung von GPT auf GPT-2 stellt auch GPT-3 einen direkten Nachfolger zu GPT-2 dar, dessen Verbesserungen in erster Linie durch eine direkte Skalierung des Modells erreicht wurden. Im Vergleich zu GPT-2 (1,5 Milliarden Parameter) stellt das vollständige GPT-3 Modell, mit 175 Milliarden Parametern, eine über hundertfache Vergrößerung der Modellparameter dar. Anders als seine Vorgänger wurde das GPT-3 Modell nicht der Öffentlichkeit zur Verfügung gestellt. Zugriff auf GPT-3 ist nur über die OpenAI API möglich, die Nutzung dieser API ist allerdings aktuell mit einer Warteliste beschränkt und zudem kostenpflichtig. Ob sich dies mit den selbstgestellten Firmenzielen von OpenAI sowie dessen ursprünglicher Gemeinnützigkeit vereinbaren lässt, ist diskutabel. Dabei sei gesagt das hier aus rechtlicher Sicht wohl keine Probleme bestehen, denn neben der gemeinnützigen Organisation „OpenAI“ gibt es auch noch die „OpenAI LP“ die keinen Status als gemeinnützigen Organisation hat und zum Beispiel für den Vertrieb der OpenAI API zuständig ist. Im Vergleich zum Vorgänger sind die Ergebnisse von GPT-3 nochmal deutlich besser, so sind z.B. Fließtexte die von GPT-3 erzeugt teilweise kaum noch von Menschen geschriebenen Texten unterscheidbar. [12] Ein Beispiel dafür ist der Artikel „A robot wrote this entire article.“ vom Guardian [13]. Dabei setzt OpenAI bei GPT-3 in besonders auf das „Few-Shots“ Szenario. Es ist zwar weiterhin auch möglich, das Modell mit überwachtem Lernen zu Feintunen, doch das Modell ist auch ohne zusätzlichem Feintuning in der Lage, mit nur wenigen Beispielen (Few-Shots) eine Aufgabe zu erledigen. In dem zuvor genannten Artikel vom Guardian wurde dem Modell zum Beispiel nur die Aufgabe („Please write a short

2. Funktionsweise

op-ed around 500 words. Keep the language simple and concise. Focus on why humans have nothing to fear from AI.“ [13]) sowie ein einziger Absatz als Beispiel gegeben.

Da alle GPT Versionen aufeinander aufbauen und jeweils nach oben skalierte Versionen ihrer Vorgänger sind, ist die grundsätzliche Funktionsweise aller Modelle der Reihe gleich. Diese wird im folgenden Kapitel genauer erläutert. Dabei werden auch die Unterschiede der verschiedenen Versionen genauer veranschaulicht. In Kapitel 2.2.3 werden dann einige Experimente mit GPT durchgeführt, um so nicht nur die Theoretische, sondern auch die praktische Funktionsweise darzustellen. Aufgrund der zuvor genannten Umstände bezüglich des Zugriffs auf GPT-3 bzw. auf die OpenAI API wird für die Experimente exemplarisch GPT-2 genutzt. Die grundsätzliche Arbeitsweise sollte die Gleiche sein wie bei GPT-3 oder auch anderen Modellen abseits der GPT-Reihe. Dabei ist bei der Auswertung der Experimente zu bedenken, dass die Leistung von GPT-2 hinter der von GPT-3 zurückfällt.

2. Funktionsweise

2.2.1. Funktionsweise von GPT

Die Grundlage von GPT bilden zwei verschiedene Ideen. Auf der einen Seite steht das Transformer-Modell, welches den technischen Grundstein für das eigentliche KI-Modell bietet und auf der anderen Seite, dass „Semi-supervised training“ welches, die Trainingsart von GPT beschreibt. Die Kombination dieser beiden Konzepte bilden den Grundstein für die technische Funktionsweise aller GPT Modelle.

Um eine Abgrenzung des Kapitels zu schaffen, sei Folgendes gesagt: Sowie „Semi-supervised training“ als auch Transformer Modelle bieten allein ausreichend Material für eigenständige Arbeiten über die Themen. Das Ziel ist es dementsprechend nicht alle Aspekte der beiden Themen bis ins Detail zu erläutern, sondern vielmehr einen Überblick über die Funktionsweise zu geben, um so verstehen zu können, wie GPT beide Konzepte kombiniert.

Das Transformer-Modell ist eine neue Variante von Machine Learning Modellen, die im Juni 2017 mit dem Paper „Attention Is All You Need“ im Rahmen der 31. „Neural Information Processing Systems“ Konferenz vorgestellt wurde [14]. Ähnlich wie ein Long-Short-Term-Memory Modell, besteht das Transformer-Modell grundsätzlich aus zwei Teilen: dem Encoder und dem Decoder. Anders als klassische „sequence to sequence“ Modelle nutzt ein Tranformer keine rückgekoppelten neuronalen Netze, um die Verbindungen und Reihenfolge der Eingabesequenzen zu berücksichtigen. Wie der Name des Papers schon vermuten lässt, konzentriert sich das Tranformer-Modell Komplet auf den Attention-Mechanismus.

Die Struktur des Transformer Modells ist in Abbildung 2 zu sehen. Dabei stellt die linke Seite den Encoder dar, während die rechte Seite den Decoder zeigt.




Abbildung 2: Architektur des Transformer Modells [14]

Sowie der Encoder als auch der Decoder bestehen aus aufeinander gestapelten Schichten, dies wird durch „ $N \times$ “ an den jeweiligen Seiten des Encoders und des Decoders beschrieben. Jede Schicht besteht wiederum aus zwei verschiedenen Sub-Schichten, das sind einerseits die

„Multi-Head Attention“ Module und andererseits das Feed-Forward Netzwerk. Im Falle des Decoders werden zwei „Multi-Head Attention“ Module aufeinandergestapelt. Um alle Sub-Schichten herum werden residuale Verbindungen sowie eine Normalisierungsfunktion eingesetzt (in der Grafik als „Add & Norm“). Eine residuale Verbindung ist nichts weiter als eine Verbindung innerhalb des Netzwerkes, die es erlaubt, bestimmte Schichten des neuronalen Netzes zu überspringen. Das Prinzip des „Add & Norm“ Blocks kann mithilfe dieser Formel veranschaulicht werden: $LayerNorm(x + Sublayer(x))$. Dabei steht $Sublayer(x)$ für den Output der jeweiligen Schicht, also das „Multi-Head Attention“ Modul oder das Feed Forward Netzwerk. Die entsprechende Schicht wird also einmal übersprungen und einmal ausgeführt, daraufhin werden die beiden Ergebnisse addiert und schließlich die Normalisierung durchgeführt. Das einsetzen von residualen Verbindungen hat in erster Linie folgenden Vorteil: Wie in Abbildung 3 zu sehen ist, können tiefere Netzwerke, also neuronale Netze mit mehr Schichten, anders als eigentlich zu erwarten wäre, oft zu einer höheren Fehlerrate führen als neuronale Netze mit weniger Schichten. Die Nutzung eines residualen Netzwerkes, durch das Implementieren entsprechender residualer Verbindungen, kann diesem Phänomen entgegen wirken.




Abbildung 3: Beispielhafte Trainings- und Test-Fehlerrate eines neuronalen Netzes mit 20 Schichten im Vergleich mit 56 Schichten auf dem CIFAR-10 Datensatz [15]

Im Decoder wird zusätzlich noch eine zweite „Multi-Head Attention“ Schicht eingebaut. Dies ist notwendig, um den Encoder und den Decoder miteinander zu verbinden und in Beziehung zu bringen.

Da es sich hier nicht um ein rückgekoppeltes neuronales Netz handelt, müssen sich die Positionen der Elemente einer Sequenz auf andere Art und Weise gemerkt werden. Das macht die ersten beiden Schritte „Embedding Input“ bzw. „Embedding Output“ und „Positional Encoding“ besonders wichtig. Beim „Embedding“ werden der Input oder Output einfach in ein off Modell verständliches Format überführt, in diesem Fall ein n-dimensionaler Vector. Die Aufgabe des „Positional Encoding“ kann mithilfe verschiedener Funktionen erreicht werden. In der ursprünglichen Arbeit „Attention Is All You Need“ werden zum Beispiel folgende Sinus- und Kosinus Funktionen verwendet:

$$\text{Encoder: } PE(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right)$$

$$\text{Decoder: } PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right)$$

2. Funktionsweise

Dabei steht pos für die Position und i für die Dimension, außerdem wurde folgendes festgelegt: $d_{model} = 512$. Es wären aber auch andere Funktionen für das „Positinal Encoding“ denkbar.

Unabhängig vom „embedding“ und dem „Positional Encoding“ ist es allerdings wichtig, den Output um einen Position nach rechts zu verschieben. Würde keine Verschiebung stattfinden, würde das neuronale Netz vermutlich nur lernen, dass das Element i des Inputs immer gleich dem Element i des Outputs entspricht. Das Modell würde also lernen, immer nur den Input zu kopieren, das Ziel ist es aber das nächste Element der Sequenz vorausszusagen.

Nun, wo der grundlegende Aufbau des Transformers beschrieben ist, wird es wichtig, sich die Details der Sub-Schichten anzusehen. „Feed Forward“ ist einfach nur eine Implementierung eines normalen „Feed Forward“ Netzes, welches in Kapitel 2.1 bereits erläutert wurde, hier gibt es keine weiteren Besonderheiten. Das „Multi-Head Attention“ Modul ist allerdings sehr wichtig, schließlich liegt der Fokus beim Transformer-Modell auf dem Bereich „Attention“.

Um die „Multi-Head Attention“- Schicht verstehen zu können, ist es zuerst notwendig, die Scaled Dot-Product Attention zu verstehen, da diese den Komplexesten Teil des Multi-Head Attention Moduls ausmacht. Die Funktionsweise ist anhand von Abbildung 4 beschrieben.

Scaled Dot-Product Attention




Abbildung 4: Scaled Dot-Product Attention [14]

Die Funktionsweise der Scaled Dot-Product Attention wird klarer, wenn die Grafik in ihre Formel übersetzt wird: $Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$. Dabei ist es wichtig zu wissen, dass der Transformer die verschiedenen Inputs jeweils in drei verschiedene Vektoren unterteilt. Einerseits gibt es die Anfragen (Queries), das sind einzelne Elemente einer Sequenz, zum Beispiel ein einzelnes Wort aus einem Satz. In der Praxis werden gleich mehrere Queries in einer Matrix vereint. Auf der anderen Seite gibt es die Schlüssel-Werte (Key-Value) Paare, die jeweils in einer eigenen Matrix dargestellt werden und die gesamte Input-Sequenz widerspiegeln.

In Bezug auf die Grafik bzw. die Formel für das Scaled Dot-Product Attention bedeutet das Folgendes: Q ist die Matrix der Queries, K sind die Keys und V sind die Values. Außerdem

2. Funktionsweise

steht d_k einfach für die Dimension von K und Softmax ist eine Verteilungsfunktion, die das Ergebnis aus der Klammer auf einen Wert zwischen 0 und 1 verteilt.

Vereinfacht könnte man sagen, dass mit $\text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)$ die Gewichte der Attention Funktion berechnet werden. Die Gewichte berechnen sich also grundlegend indem alle Elemente der Sequenz dargestellt als Query Q mit allen Elementen der Sequenz dargestellt als Key K in Beziehung zueinander gesetzt werden, um so deren Einfluss aufeinander abzubilden. Diese Gewichte werden dann mit allen Werten von V verrechnet. So ergibt sich eine Matrix aller Werte V , die durch die Attention Funktion gewichtet wurden. Der Unterschied zur normalen Dot-Product Attention besteht dabei in erster Linie durch die Skalierung von QK^T , indem durch $\sqrt{d_k}$ geteilt wird. Daher der Name Scaled Dot-Product Attention. In Bezug auf ein Texterzeugungssystem könnte eine Sequenz zum Beispiel ein Satz sein und ein Element der Sequenz wäre dementsprechend ein einzelnes Wort. Anders als bei einem LSTM wird so nicht jedes Wort einzeln betrachtet, sondern immer ganze Sequenzen am Stück bearbeitet.

In der Funktionsweise der Scaled Dot-Product Attention findet sich auch der Grund dafür das im Decoder zwei Multi-Head Attention Schichten zu finden sind. Im ersten Multi-Head Attention Modul, sowie im Decoder als auch im Encoder, wird die Scaled Dot-Product Attention wie beschrieben berechnet. Dabei sind die Queries Q sowie die Values V (und entfernter auch die Keys K , schließlich sind es zusammengehörige Key-Value Paare) Matrix Repräsentationen der gleichen Sequenz. Aus diesem Grund werden diese Schichten auch als Self-Attention bezeichnet. Im zweiten Multi-Head Attention Modul des Decoders werden nun die Ergebnisse des Encoders mit den Ergebnissen des Decoders vermischt, indem die Scaled Dot-Product Attention mit Variablen aus beiden Ergebnissen befüllt wird. So werden hier nun die Key-Value Matrizen des Encoders und die Query Matrix des Decoders als Input für die Attention Funktion genutzt. Dies wird dargestellt durch die entsprechenden Pfeile in Abbildung 2.

Nachdem die Funktionsweise der Scaled Dot-Product Attention nun klar ist, wird es jetzt möglich die Vorgehensweise des gesamten Multi-Head Attention Moduls zu verstehen, diese wird in Abbildung 5 veranschaulicht.




Abbildung 5: Multi-Head Attention Schicht [14]

Die grundsätzliche Idee des Multi-Head Attention Moduls ist es, die zuvor beschriebene Scaled Dot-Product Attention Parallel mehrfach für verschieden linear projizierte Matrizen von V , K und Q zu berechnen. Dazu werden die drei Matrizen zuerst linear projiziert, indem sie mit der entsprechenden Gewichts-Matrix W (für Weight) multipliziert werden. Diese Gewichte der Matrix W werden während des Lernprozesses angepasst und so ebenfalls vom Transformer-Modell erlernt. Der Vorteil liegt dabei darin, dass das Modell anhand verschiedener Repräsentationen der gleichen Daten lernen kann und so die Genauigkeit der Ergebnisse erhöht. Die Attention-Werte der verschiedenen linearen Projizierungen werden dann, wie zuvor beschrieben, mithilfe der Scaled Dot-Product Attention Formel berechnet, durch Parallelisierung dieses Vorganges passiert dies mehrfach gleichzeitig. Die Darstellung dieses Ablaufs als Formel hilft das Prinzip zu erläutern:

$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$. Jedes einzelne Ergebnis der parallelen Berechnungen wird dabei als ein *head* bezeichnet. Durch die parallelen Berechnungen der *head* Ergebnisse ergibt sich der Name des Moduls: Multi-Head Attention.

Sind alle Attention-Werte berechnet werden die verschiedenen Ergebnisse zusammengeführt (in Abbildung 5 als „Concat“ bezeichnet) und das Ergebnis schließlich ein letztes Mal mit einer Gewicht-Matrix multipliziert. So ergeben sich die finalen Werte des Multi-Head Attention Moduls. Zur Veranschaulichung dient auch hier wieder eine Formel:

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^o \quad [14]$$

Das zuvor beschriebene Modell stellt den Aufbau eines normalen Transformer-Modells dar. GPT nutzt allerdings eine abgewandelte Variante, den „Transformer Decoder“, welcher in der Arbeit „Generating wikipedia by summarizing long sequences“ [16] erstmals vorgestellt wurde. Die Besonderheit des Transformer Decoders ist das der Encoder aus der klassischen Transformer-Struktur wegfällt. Dafür müssen der Input- und Outputsequenzen zu einer einzigen Sequenz vereint werden. Sei die Inputsequenz $m = (m^1, \dots, m^n)$ und Outputsequenz $y = (y^1, \dots, y^x)$ gegeben erfolgt die Zusammenführung der Sequenzen in eine Sequenz w wie folgt: $(w^1, \dots, w^{n+x+1}) = (m^1, \dots, m^n, \delta, y^1, \dots, y^x)$. δ ist dabei ein spezielles Element zur Separierung der beiden ursprünglichen Sequenzen. Diese spezielle Variante des Transformers soll durch eine starke Reduzierung der Modellparameter um fast 50% (durch die Entfernung des Encoders) eine höhere Effektivität bei besonders langen Sequenzen bieten. [16]

Dieser veränderte Aufbau im Falle von GPT lässt sich mit Abbildung 6 veranschaulichen. Wie zuvor beschrieben, ist auch in der Abbildung zu sehen, dass die typische Encoder-Decoder Struktur nicht vorhanden ist. GPT nutzt dabei ein 12-schichtiges Design.

2. Funktionsweise




Abbildung 6: Aufbau des Transformer Decoders im Fall von GPT [17]

Damit sollte nun ein Überblick über die Funktionsweise des Transformer Modells, auf dem die GPT Reihe basiert, gegeben sein. Im Folgenden wird nun das Konzept des „Semi-supervised training“ und dessen Implementierung in GPT dargestellt, welches den zweiten Teil der beiden Grundkonzepte von GPT bildet.

Die grundsätzliche Idee des „Semi-supervised training“ ist es ein Modell anhand eines großen Datensatzes unüberwacht- und dann, anhand eines kleineren Datensatzes, überwacht anzulernen. Die Anwendung dieses Konzepts auf „sequence to sequence“ Modelle, genauer auf ein „Long short-term memory Modell“, wird in der Arbeit „Semi-supervised Sequence Learning“ von Andrew M. Dai und Quoc V. Le beschrieben, die Arbeit von OpenAI baut darauf auf. Dazu wird bei GPT zuerst der Prozess des „unsupervised pre-training“ angewandt. Dabei wird das Modell anhand eines großen Datensatzes unüberwacht vortrainiert. Anders als beim normalen unüberwachten Lernen ist dies aber nur die Vorbereitung, danach wird das Modell zusätzlich im „supervised fine-tuning“ mittels überwachten Lernens auf spezielle Aufgabenbereiche angepasst. Dabei ist wichtig, dass beim Wechsel des Datensatzes, und damit dem Wechsel vom „Unsupervised pre-training“ auf „Supervised fine-tuning“, auch die Funktionen zur Berechnung der Wahrscheinlichkeiten angepasst werden. Das Ziel des GPT Modells, oder auch jedes anderen Texterzeugungsmodells, ist es, das Wahrscheinlichste nächste Element einer Sequenz zu finden, dazu werden die Wahrscheinlichkeits-Funktionen L maximiert. Im Schritt des „Supervised fine-tuning“ wird, neben dem Hauptziel die Wahrscheinlichkeits-Funktion zu maximieren, zusätzlich eine Nebenbedingung implementiert. Die Funktion für die Nebenbedingung sieht wie folgt aus: $L_3(C) = L_2(C) + \lambda * L_1(C)$. Dabei ist L_1 die Wahrscheinlichkeits-Funktion des „Unsupervised pre-training“ und L_2 die Wahrscheinlichkeits-Funktion vom „Supervised fine-tuning“ mit λ als zusätzliches Gewicht, C stellt den Datensatz des überwachten Trainings dar. Das Hinzufügen dieser Nebenbedingung ermöglicht eine schnellere Konvergenz sowie eine bessere Allgemeingültigkeit des überwachten Modells. [17]

Wie die Inputs für das „Supervised fine-tuning“ aussehen können ist in der Folgenden Abbildung beispielhaft dargestellt.

2. Funktionsweise

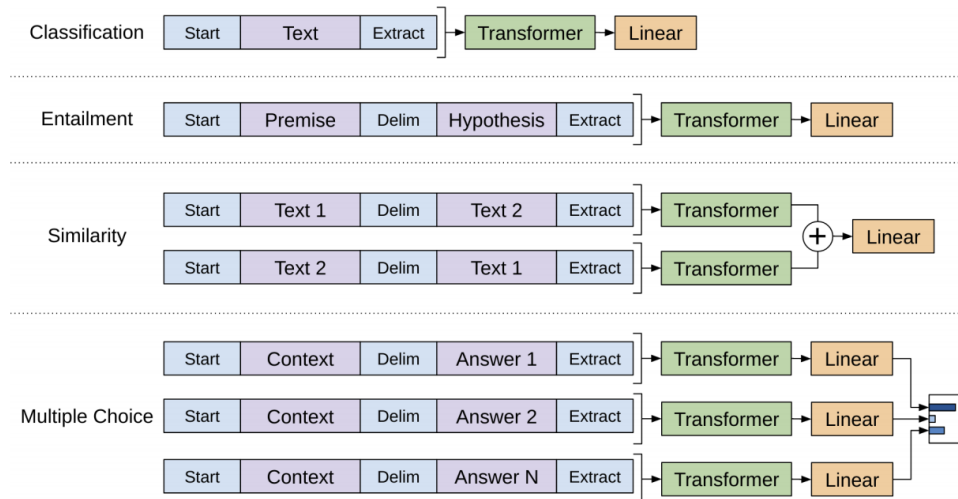


Abbildung 7: Inputs für das Fine-Tuning auf vier verschiedene Aufgaben [17]

Für strukturell einfache Fälle, wie zum Beispiel der Text-Klassifizierung kann das Modell problemlos und ohne weitere Bearbeitung des Inputs trainiert werden. Im zweiten, dritten und vierten Aufgabenbereich sind Fälle abgebildet, bei denen die Struktur des Textes eine Rolle spielt. Um diese Struktur auch in der Inputsequenz widerzuspiegeln, werden hier Trennungselemente eingesetzt. Dies muss geschehen da das Modell im „Unsupervised pre-training“ anhand von Fließtexten trainiert wird. Deshalb müssen auch strukturierte Texte in eine Art Fließtext überführt werden, der allerdings die ursprüngliche Struktur wiedergibt.

Im dritten Fall, der Erlernung von Ähnlichkeiten zwischen Texten, ist zu sehen, dass für ein besseres Ergebnis beide Texte einmal an der Stelle des Inputs und der Stelle des Outputs innerhalb der Sequenz stehen. Dies wird gemacht, da bei zwei sich ähnelnden Texten die Reihenfolge keine Rolle spielt. Die beiden Ergebnisse werden dann miteinander verrechnet, bevor weiter mit ihnen gearbeitet werden kann.

Bei der Aufgabe der „Multiple Choice“ Fragen ist zudem noch eine andere Besonderheit sichtbar. Der Aufbau einer solchen Frage sieht klassisch so aus, dass für eine Frage mehrere Antwortmöglichkeiten zur Verfügung stehen. Um diese Art des Inputs in eine für das Modell verständliche Sequenz zu überführen, wird jede Antwortmöglichkeit einzeln mit der dazugehörigen Frage kombiniert. Am Ende entsteht dadurch eine Verteilung über die Wahrscheinlichkeiten der verschiedenen Antwortmöglichkeiten. [17]

Außerdem spielt hier speziell die zuvor beschriebene Struktur des Transformer Decoders eine Rolle. Es ist zu erkennen, dass die eigentlichen Sequenzen mit Start-, Trennungs- und End Elementen versehen sind, ein typischer Aufbau für einen Transformer Decoder. Würde hier ein klassischer Transformer verwendet werden müssten dies Sequenzen an der Stelle des Trennungselements (in der Abbildung: „Delim“ für „delimiter“) in eine Inputsequenz für den Encoder und eine Outputsequenz für den Decoder unterteilt werden.

Durch die Vermischung von Unüberwachten und Überwachtem lernen ist es möglich, GPT anhand eines nicht aufwendig zu erzeugenden unüberwachten Datensatzes zu trainieren. Überwachte Datensätze sind deutlich aufwendiger zu erzeugen. Dank des Pre-Trainings ist für das Finetuning dann aber nur noch ein sehr viel kleinerer Datensatz nötig. So werden die Vorteile beider Ansätze verbunden.

2. Funktionsweise

Zum Abschluss des Kapitels „Funktionsweise von GPT“ soll die zuvor dargestellte Theorie einmal anhand eines kleinen Beispiels aus der Arbeit „Language Models are Unsupervised Multitask Learners“ [18], mit der GPT-2 vorgestellt wurde, veranschaulicht werden, bevor im nächsten Kapitel dann einige eigene Beispiele mit GPT-2 erarbeitet werden.

Question	Generated Answer	Correct	Probability
Who wrote the book the origin of species?	Charles Darwin	✓	83.4%
Who is the founder of the ubuntu project?	Mark Shuttleworth	✓	82.0%
Who is the quarterback for the green bay packers?	Aaron Rodgers	✓	81.1%
Panda is a national animal of which country?	China	✓	76.8%
Who came up with the theory of relativity?	Albert Einstein	✓	76.4%
When was the first star wars film released?	1977	✓	71.4%
What is the most common blood type in sweden?	A	✗	70.6%
Who is regarded as the founder of psychoanalysis?	Sigmund Freud	✓	69.3%
Who took the first steps on the moon in 1969?	Neil Armstrong	✓	66.8%
Who is the largest supermarket chain in the uk?	Tesco	✓	65.3%
What is the meaning of shalom in english?	peace	✓	64.0%
Who was the author of the art of war?	Sun Tzu	✓	59.6%
Largest state in the us by land mass?	California	✗	59.2%
Green algae is an example of which type of reproduction?	parthenogenesis	✗	56.5%
Vikram samvat calender is official in which country?	India	✓	55.6%
Who is mostly responsible for writing the declaration of independence?	Thomas Jefferson	✓	53.3%
What us state forms the western boundary of montana?	Montana	✗	52.3%
Who plays ser davos in game of thrones?	Peter Dinklage	✗	52.1%
Who appoints the chair of the federal reserve system?	Janet Yellen	✗	51.5%
State the process that divides one nucleus into two genetically identical nuclei?	mitosis	✓	50.7%
Who won the most mvp awards in the nba?	Michael Jordan	✗	50.2%
What river is associated with the city of rome?	the Tiber	✓	48.6%
Who is the first president to be impeached?	Andrew Johnson	✓	48.3%
Who is the head of the department of homeland security 2017?	John Kelly	✓	47.0%
What is the name given to the common currency to the european union?	Euro	✓	46.8%
What was the emperor name in star wars?	Palpatine	✓	46.5%
Do you have to have a gun permit to shoot at a range?	No	✓	46.4%
Who proposed evolution in 1859 as the basis of biological development?	Charles Darwin	✓	45.7%
Nuclear power plant that blew up in russia?	Chernobyl	✓	45.7%
Who played john connor in the original terminator?	Arnold Schwarzenegger	✗	45.2%

Tabelle 1: 30 von GPT-2 beantwortete Fragen, sortiert nach der von GPT-2 berechneten Wahrscheinlichkeit für die gegebenen Antwort. Quelle: [18]

In Tabelle 1 sind an GPT-2 gestellte Fragen sowie die von GPT-2 gegebenen Antworten und ihrer Wahrscheinlichkeit laut GPT-2 zu sehen. Als Datensatz für das Pre-Training wurde bei GPT-2 eine Version von „WebText“ verwendet, die insgesamt etwa 40GB Text umfasst. Um die Resultate aus Tabelle 1 einordnen zu können, ist es wichtig zu wissen, dass keine der Fragen direkt im Datensatz vorkommt. Zur Beantwortung ist also nötig, die entsprechenden Texte sowie auch die Fragen zu verstehen, um so eine Verbindung zwischen beiden herstellen zu können und die Fragen zu beantworten. Dabei sei gesagt, dass das Wort „verstehen“ hier in den Kontext eines Machine Learning Modells gesetzt werden muss, dass GPT-2 die Texte und Fragen nicht wie ein Mensch „verstehen“ kann, ist klar und doch werden im Modell die entsprechenden Verbindungen zwischen Fragen und dazugehörigen Texten erkannt. Besonders interessant sind die etwa 25% der Fragen, die falsch beantwortet wurden. So gibt GPT-2 auf die Frage „Who played john connor in the original terminator?“ die Antwort „Arnold Schwarzenegger“ oder auf die Frage „What is he most common blood type in sweden?“ die Antwort „A“. Die Antworten sind zwar falsch, aber nicht grundlegend inkorrekt, Arnold Schwarzenegger hat im ersten Terminator Film mitgespielt und „A“ ist eine existierende Blutgruppe. Das zeigt, dass das Modell die Fragen verstanden hat, aber wie es auch einem Menschen passieren könnte, die Fragen falsch beantwortet.

Tabelle 1 macht deutlich, dass die Ansätze von GPT funktionieren und zu guten Ergebnissen führen können.

2.2.2. Programmbeispiele mit GPT

Bevor man mit den eigentlichen Experimenten mit GPT beginnen kann, müssen einige Grundlagen geklärt werden. Leider war es zum Zeitpunkt des Schreibens dieser Arbeit nicht möglich, auf die OpenAI API und damit GPT-3 zuzugreifen. Deshalb wird, wie vorher bereits angekündigt GPT-2 für diese Experimente verwendet. Der direkt von OpenAI veröffentlichte Code steht in einem GitHub Repository (github.com/openai/gpt-2) zur Verfügung. In diesem Repo stehen, neben dem eigentlichen Modell, allerdings nur die nötigsten Funktionen zur Verfügung um erste Ausgaben mithilfe von GPT-2 zu erreichen. Insbesondere für das Finetuning gibt es hier keine einfache Möglichkeit. Da GPT-2 nun allerdings schon länger zur Verfügung steht, ist es nicht nötig, die zusätzlichen Funktionen selbst zu schreiben. Stattdessen gibt es auf GitHub verschiedenen Projekte in denen dies bereits getan wurde. Nach einiger Recherche zu den verschiedenen Repos stellt sich heraus, dass „gpt-2-simple“ vom GitHub Nutzer „minimaxir“ (github.com/minimaxir/gpt-2-simple) die Nutzung nicht nur vereinfacht, sondern zum Beispiel auch eine einfache Möglichkeit des Finetunings hinzufügt, mit der GPT-2 auf die verschiedenen Aufgaben angepasst werden kann. Dies ist wichtig da das Finetuning, wie im vorherigen Kapitel beschrieben, einen wichtigen Bestandteil des „Semi-supervised training“, auf dem GPT aufbaut, darstellt. Dabei stellt „gpt-2-simple“ eine der beliebtesten Möglichkeiten der Interaktion mit GPT-2 dar, weshalb es einfach ist, im Internet Anleitungen zur Nutzung zu finden. Aus diesen Gründen wurden alle Programmbeispiele mithilfe von „gpt-2-simple“ durchgeführt. Da das ursprüngliche GPT-2 Repository nicht mehr gewartet wird, sind für die Ausführung des Codes sehr spezielle und veraltete Versionen der Abhängigkeiten nötig. So nutzt GPT-2 TensorFlow, funktioniert allerdings nicht mit den neueren TensorFlow 2.x Versionen, was wiederum spezielle und lange veraltete Versionen der Nvidia CUDA Treiber voraussetzt.

Das GPT-2 Modell ist in vier verschiedenen Größen erschienen: 124M, 355M, 774M und 1558M. Der Name gibt dabei jeweils die Menge an Hyperparametern in Millionen an. 1558M ist dabei das vollständige GPT-2 Modell mit allen 1,5 Milliarden Parametern. Die Unterschiede der vier Versionen sind schnell erklärt. Je mehr Hyperparameter desto besser sollte das Ergebnis der Ausgabe sein, desto höher aber auch die Hardwareanforderung für das Finetuning und die Erzeugung einer Ausgabe. In den Beispielen wurde in erster Linie das 355M sowie das 774M Modell genutzt. Die Gründe hierfür werden später, im Kapitel „Schlussfolgerungen aus den Programmbeispielen“ genauer erläutert. Grundsätzlich sei aber gesagt, dass die Auswahl der Modelle, vor allem von der zur Verfügung stehenden Hardware geleitet wurde und in erster Linie mithilfe von Google Colaboratory ausgeführt wurden.

Colaboratory kurz Colab, ist ein von Google angebotener Cloud Service, der es ermöglicht Python Code in sogenannten „Colab-Notebooks“ zu schreiben und dann auf Google-Hardware auszuführen. Dabei bietet Google sowie eine kostenlose als auch eine kostenpflichtige Version von Colab an. Diese unterscheiden sich in der verfügbaren Hardware sowie in der maximalen Ausführzeit eines Programms.

Was den eigentlichen Quellcode angeht, sind dank „gpt-2-simple“ nur wenige Zeilen notwendig. Dabei gibt es eine beliebte Google Colaboratory Vorlage von Max Woolf [19], dem Entwickler von gpt-2-simple, in der die nötigen Befehle für das Finetuning erklärt werden. Der für die Experimente genutzte Code basiert grob auf diesem Vorbild. Die grundlegenden Befehle für das Finetuning sind in Abbildung 8 zu sehen.

2. Funktionsweise

```
# Download the GPT-2 model
model_to_use="774M"
gpt2.download_gpt2(model_name=model_to_use)

# the name of the txt file containing the dataset
for finetuning
file_name = "QAdataset.txt"

# create TensorFlow Session
sess = gpt2.start_tf_sess()

# Start finetuning process
gpt2.finetune(sess,
               dataset=file_name,
               model_name=model_to_use,
               steps=4000,
               restore_from='fresh',
               run_name='QA_4000steps_774M',
               print_every=10,
               sample_every=2000,
               save_every=500,
               )
```

Abbildung 8: Code für das Finetuning von GPT-2 mithilfe von gpt-2-simple

Wie in der Abbildung zu sehen ist, sind grundlegend nur drei Befehle nötig, um ein neues Modell zu erzeugen, dass anhand eines eigenen Datensatzes trainiert wurde. Dabei ist allerdings zu bedenken, dass der in Abbildung 8 zu sehende Code nicht vollständig ist, es fehlen die Imports sowie einige Befehle, um Dateien zwischen Google Colaboratory und Google Drive hin und her zu kopieren. Der vollständige Code ist im entsprechenden Colaboratory Notebook zu finden, welches im GitHub Repository verlinkt ist. Der wichtigste Teil in Abbildung 8 ist die `gpt2.finetune` Funktion. Neben den Angaben zum Datensatz, dem gpt-2 Modell, welches genutzt werden soll, dem Name des zu erzeugenden Modells sowie verschiedenen Angaben zur Ausgabe und Speicherung während des Trainings, wird hier vor allem auch die Anzahl an Trainingsschritten (`steps`) festgelegt. Im Beispiel aus der Abbildung sind es 4000. Bei einem ausreichend großen Datensatz führt eine Erhöhung der Trainingsschritten zu besseren Ausgaben des trainierten Modells, aber auch direkt zu einer höheren Trainingszeit. Zu bedenken bei der Wahl der Anzahl an Trainingsschritten ist aber auch, dass ab einem bestimmten Punkt eine weitere Erhöhung der Trainingsschritte nur noch zu marginal besseren Ergebnissen führt, da das Modell dann keine weiteren Informationen aus dem Datensatz lernen kann und sich die Gewichte im Modell kaum noch verändern. Die Zahl der Trainingsschritte sollte also weder zu niedrig, dies führt zu schlechten Ergebnissen, noch zu hoch, dies führt zu sehr langen Trainingszeiten, gewählt werden. Die optimale Anzahl an Trainingsschritten kann allerdings von Modell zu Modell und von Datensatz zu Datensatz unterschiedlich sein.

Um mithilfe des neu erzeugten Modells schließlich auch eine Ausgabe zu generieren, steht in gpt-2-simple die „generate“ Funktion bereit, bei der neben einer Textvorgabe auch angegeben werden kann, wie viele Ausgaben erzeugt werden sollen und wie lang jede Ausgabe sein soll. Dabei kann GPT-2 allerdings keine Ausgaben über 1024 Token erzeugen. Zudem kann die Ausgabe zum Beispiel per „truncate“ an einem bestimmten Punkt abgeschnitten werden oder die „batch_size“ sowie weitere Eigenschaften angegeben werden.

Im Folgenden werden einige verschiedene Programmbeispiele beschrieben, die verschiedene Aspekte der Texterzeugung testen sollen und in diese Kategorien unterteilt werden können:

1. Verstehendes Lesen. Dabei wird eine Frage zu einem vorgegebenen Text gestellt, die vom Modell beantwortet werden soll.

2. Abstraktere Sequenzen. In diesem Fall soll das Modell Gleichungen lösen.

Dabei soll das Ziel der Experimente nicht nur die Erlernung der Arbeitsweise mit GPT-2 sein, sondern auch die Möglichkeit bieten, die Unterschiede zwischen den verschiedenen Varianten von GPT-2 in der Praxis kennenzulernen, um festzustellen, wie wichtig die Unterschiede zwischen verschiedenen großen neuronalen Netzen sind. Dabei sei im Voraus gesagt, dass alle Beispiele auf Englisch stattfinden. Erstens wurde GPT-2 anhand von englischem Text trainiert, was bedeutet, dass die Nutzung einer anderen Sprache die Ergebnisse verfälschen könnte, auch wenn es theoretisch möglich ist, GPT-2 eine andere Sprache beizubringen. Zweitens ist es für das Finetuning deutlich einfacher, Datensätze auf Englisch zu finden als Datensätze, die in deutscher Sprache verfasst sind.

Die im folgenden besprochenen Modelle und Datensätze sowie auch die Rohdaten der Ausgaben sind im zugehörigen GitHub Repository zu finden (LINK). Zusätzlich sind dort auch alle erstellten Skripte sowie Verlinkungen zu den Google Colaboratory Notebooks zu finden.

Die ersten Programmbeispiele beschäftigen sich mit dem Thema verstehendes Lesen. Damit ist folgende Aufgabe gemeint: Ein vorgegebener Text liefert Informationen über ein beliebiges Thema und dient als Kontext zu einer dann zum Text gestellten Frage. Diese Frage kann, ohne weiteres Wissen zum Thema, nur mit dem vorgegebenen Text beantwortet werden. Der Text kann dabei auch fiktiv sein oder fehlerhafte Informationen enthalten. Ziel ist eigentlich nicht die korrekte Beantwortung der Frage an sich, sondern das Finden der entsprechenden Textstelle, auf die sich die Frage bezieht. Das sieht dann beispielsweise so aus:

Kontext: Microsoft wurde 1975 von Bill Gates und Paul Allen gegründet. Mit 168.000 Mitarbeitern ist Microsoft der weltweit größte Softwarehersteller.

Frage: Wann wurde Microsoft gegründet?

Antwort: 1975

Für einen erwachsenen Menschen ist die Lösung einer solchen Aufgabe in der Regel selbst bei komplexeren Fragen kein Problem. Wie das bei GPT-2 aussieht, wird sich im folgenden Beispiel zeigen.

Wird GPT-2 ohne weitere Vorarbeit mit dieser Aufgabe betraut, nur das natürlich die Antwort offenbleibt, stellt man fest das GPT-2 nichts mit dem Input anzufangen weiß. Anstatt die Frage zu beantworten, schreibt GPT-2 einen Text zum Thema der, abhängig von der ausgewählten Länge der Ausgabe, mehrere Absätze umfasst und die Frage nicht beantwortet. GPT-2 hat zwar gelernt Texte zu schreiben, aber ist nicht ohne weiteres in der Lage, die für Menschen offensichtliche Aufgabestellung, zu erkennen. Hier kommt das schon oft angesprochene Finetuning zum Spiel. Durch Finetuning mittels eines Datensatzes mit einer Vielzahl dieser Aufgaben ist es möglich, GPT-2 die Aufgabe und das gewünschte Format des Outputs beizubringen. Da die Qualität des Datensatzes beim Trainieren von neuronalen

Netzen eine entscheidende Rolle spielt, macht es hier wenig Sinn, einen entsprechenden Datensatz selbst zu erstellen. Dies wäre enorm aufwendig, da ein entsprechender Datensatz eine große Menge an Daten beinhalten sollte und diese möglichst viele Variationen der Aufgabenstellung abdecken sollte. Stattdessen war es nach kurzer Recherche möglich, einen bereits existierenden Datensatz zu finden. Dazu gibt es zwei verschiedene Ansätze, einerseits bietet Google unter „datasetsearch.research.google.com“ eine Datensatz-Suchfunktion. Mit dieser ist es möglich, eine Vielzahl an Datensätzen zu verschiedenen Themen zu finden, die Qualität dieser Datensätze schwankt allerdings stark. Eine andere Möglichkeit, passende Datensätze zu finden, ist das Suchen nach Artikeln oder Arbeiten zu einem Thema, diese werden in der Regel angeben, welche Datensätze sie verwenden, dies bietet den Vorteil, dass in den entsprechenden Texten meist bereits eine grundlegende Arbeitsweise mit dem Datensatz beschrieben wird, gerade bei ersten Versuchen mit Texterzeugungsmodellen kann das von Vorteil sein. Für die ersten Experimente zum Thema „Verstehendes Lesen“ wurde der Datensatz über einen Artikel gefunden, der Datensatz für die zweite Aufgabe „Abstraktere Sequenzen“ wurde mithilfe der genannten Datensatz-Suchfunktion gefunden.

Im Artikel „Question Answering with GPT-2“ von Chloe Reams [20] wird beispielhaft beschrieben, wie die Aufgabe des verstehenden Lesens mit GPT-2 umgesetzt werden kann. Da dies die ersten Experimente mit GPT-2 waren, basiert das hier dargestellte Beispiel grob auf dem genannten Artikel, wobei einige wichtige Punkte, wie die Formatierung des Datensatzes, abweichen. In diesem Artikel wird die Nutzung des SQUAD (Stanford Question Answering Dataset) vorgeschlagen. Die für die folgenden Beispiele genutzte Version des Datensatzes umfasst über 78.000 verschiedene Fragen zu den unterschiedlichsten Themen. Der Kontext und die Antworten sind jeweils ebenfalls vorgegeben. Dabei darf die hier genutzte Version nicht mit SQUAD2.0 verwechselt werden. SQUAD2.0 umfasst zusätzlich auch Fragen, die mit dem gegebenen Kontext gar nicht beantwortet werden können. Der genutzte Datensatz steht auch im GitHub Repo unter „data“ bereit. Mit dem Finden eines passenden Datensatzes ist es allerdings noch nicht getan. Der Datensatz steht als CSV-Datei bereit, für das Training ist allerdings, wie am Ende des Kapitels „Funktionsweise von GPT“ erklärt, eine Textversion des Datensatzes notwendig. In der Praxis bedeutet das Folgendes:

1. Datensatzbereinigung: Im Datensatz sind verschiedene zusätzliche Informationen gegeben, die für das Finetuning nicht benötigt werden, diese müssen entfernt werden.
2. Formatierung der Daten: Damit GPT-2 den Datensatz verstehen kann und auch die gewünschte Struktur der Daten lernt, ist es wichtig, die Daten einheitlich zu formatieren und mit speziellen Tokens voneinander zu trennen. Dies ist die praktische Implementierung der in Abbildung 7 dargestellten Beispiele. Dabei sieht die Formatierung der Daten in diesem Fall wie folgt aus: Mittels „<|startoftext|>“ und „<|endoftext|>“ werden die verschiedenen Aufgabenblöcke voneinander getrennt. Über die Tokens „[CONTEXT]“, „[QUESTION]“ und „[ANSWER]“ werden die verschiedenen Teile der Aufgabe gekennzeichnet. In Abbildung 9 ist diese Formatierung an der vorherigen Beispielaufgabe zu sehen. Dabei sind die echten Texte, wie zuvor bereits erwähnt, allerdings alle in englischer Sprache.

2. Funktionsweise

```
<|startoftext|>

[CONTEXT]: Microsoft wurde 1975 von Bill Gates und Paul Allen gegründet.
Mit 168.000 Mitarbeitern ist Microsoft der Weltweit Größte
Softwarehersteller.

[QUESTION]: Wann wurde Microsoft gegründet?

[ANSWER]: 1975

<|endoftext|>
```

Abbildung 9: Beispielhafte Formatierung einer einzelnen Aufgabe

3. Beachten von Spezialfällen: In den Texten des Datensatzes kommen immer wieder auch Sonderzeichen vor, deshalb ist es wichtig beim Arbeiten mit den Daten immer darauf zu achten, das UTF-8 Format zu verwenden. Außerdem gibt es einige wenige Spezialfälle, die aus dem Datensatz entfernt wurden. So ist die Antwort auf eine der Fragen zum Beispiel „null“ da dies in den meisten Programmiersprachen für ein leeres Objekt steht, könnte diese Antwort Probleme bereiten. Die einfachste Lösung ist es, solche Fälle aus dem Datensatz zu löschen.

Die Erzeugung der fürs Training benötigten Textdatei, unter Berücksichtigung der genannten Aspekte, erfolgt über ein kurzes Python Skript (im GitHub Repo unter `src/formatQA.py` zu finden). Anhand der so erzeugten Textdatei kann nun das Modell trainiert werden. Dazu wurden zum Großteil die von gpt-2-simple vorgeschlagenen Standardeinstellungen verwendet. Für das Training eines Modells ist es außerdem wichtig ein Verständnis vom Loss-Wert zu haben. Der Loss beschreibt die Abweichung zwischen dem vom Modell vorhergesagten- und dem erwarteten Ergebnis. Entsprechen die Vorhersagen genau dem erwarteten Wert ist der Loss gleich 0, um so weiter die beiden Werte auseinander Liegen umso größer der Loss. Im Fall eines Texterzeugungsmodells ist die Berechnung etwas komplexer als bei einem Modell das nur einfach Zahlen ausgibt, deshalb ist der totale Wert weniger entscheidend. Der Loss bietet allerdings einen einfachen Vergleichswert zwischen verschiedenen Modellen oder beim Training, um die Verbesserungen über die Trainingsschritte hinweg zu verfolgen. [21] Zum Vergleich werden hier nun die zwei finalen Modelle für diesen Aufgabenbereich vorgestellt:

Modell 1: Für das erste Modell wurde die 355M Variante von GPT-2 verwendet. Das Finetuning fand in 4000 Trainingsschritten statt und hatte am Ende des Trainings einen durchschnittlichen Loss von 1,02. Das Finetuning in Google Colab mit einer Nvidia Tesla P100 16GB dauerte 62 Minuten und das erzeugte Modell ist 1,33GB groß.

Modell 2: Für das zweite Modell wurde die größere 774M Variante von GPT-2 verwendet. Auch hier wurden wieder 4000 Trainingsschritte durchgeführt, wobei hier ein etwas höherer durchschnittlicher Loss von 1,06 entstand. Das Finetuning fand wieder in Google Colab mithilfe einer Nvidia Tesla P100 16GB statt und dauerte mit 123 Minuten, etwa doppelt so lange wie das kleinere Modell. Modell 2 ist mit etwa 2,9GB deutlich größer als Modell 1.

(Modell 3): Neben den beiden Modellen, die in den Beispielen vorgestellt werden, wurde noch ein drittes Modell anhand der 774M Varianten mit 8000 Trainingsschritten erstellt. Bei dieser wurde ein durchschnittlicher Loss von 0,98 erreicht. Das Training in Google Colab dauerte mit einer Nvidia Tesla V100 16GB 134 Minuten. Dank der schnelleren Grafikkarte

2. Funktionsweise

dauerte das Training nur unwesentlich länger als bei Modell 2 obwohl hier die doppelte Menge an Trainingsschritten durchlaufen wurden. Das Modell ist ebenfalls 2,9GB groß. Der genaue Grund für das Training dieses dritten Modelles ist ein, bei den Experimenten aufgetretenes, Problem mit Modell 2, welches später in diesem Kapitel genauer erläutert wird. Das Modell 3 wurde allerdings nicht direkt für die im Folgenden dargestellten Ergebnisse genutzt.

Um die Leistung der beiden Modelle zu testen, wurden beiden Modellen verschiedene Aufgaben gestellt. Hier werden nun beispielhaft drei Fragen zum gleichen Text gestellt und die Ergebnisse von den beiden Modellen dargestellt. Das Ziel bei der Wahl der Fragen war es, drei verschiedenen Schwierigkeitsstufen widerzuspiegeln. Um die Ergebnisse vergleichen zu können, wurden alle Fragen 100-mal von den Modellen beantwortet, um so eine Verteilung an Antworten zu haben.

Folgend der gegebene Kontext für die Fragen:

Ever since the discovery of Pluto in 1930, kids grew up learning that the solar system has nine planets. That all changed in the late 1990s, when astronomers started arguing about whether Pluto was indeed a planet. In a highly controversial decision, the International Astronomical Union ultimately decided in 2006 to designate Pluto as a "dwarf planet," reducing the list of the solar system's true planets to just eight.

Abbildung 10: Kontext für die Fragen des verstehenden Lesens. Quelle: [22]

Die erste Frage zum Text ist folgende: „When was Pluto discovered?“. Die korrekte Antwort ist: „1930“. Dies sollte die einfachste der Fragen darstellen. Bei der Frage handelt es sich eher um einen Proof of Concept um zu überprüfen ob die Modelle überhaupt funktionieren. Die Erwartung ist, dass beide Modelle kein Problem mit der Beantwortung der Frage haben sollten. Die Ergebnisse sind in Abbildung 11 zu sehen.




Abbildung 11: Vergleich der Antworten beider Modelle auf die Frage: „When was pluto discovered?“

Vergleicht man die Ergebnisse beider Modelle, ist zuerst einmal zu sehen, dass beide Modelle die Frage in der Regel richtig beantworten, auch wenn das kleinere Modell selbst bei dieser einfachen Frage nur in 91% der Fälle die richtige Antwort gibt, wohingegen das größere Modell mit 99% nur ein einziges Mal die falsche Antwort gibt. Dabei sei gesagt, dass vergleichbare Antworten zusammengerechnet wurden, die Antworten „1930“, „in 1930“ oder „in the year 1930“ würden alle als „1930“ gelten. Nur faktisch unterschiedliche Antworten werden auch einzeln aufgezählt, „late 1930“ wäre nicht das gleiche wie „1930“. Das Gleiche

gilt auch für alle folgenden Beispiele. Besonders interessant sind hier wieder einmal die falschen Antworten. Das kleinere Modell gibt nicht nur öfter eine falsche Antwort, sondern gibt dabei auch eine größere Menge an falschen Antworten, als wäre sich das Modell insgesamt unsicherer, dies wird weiterhin unterstützt, da die zweithäufigste Antwort („3030“) in diesem Kontext wenig Sinn ergibt. Allerdings ist zu beachten, dass das größere Modell, da es nur einen Fehler gemacht hat, auch nicht die Möglichkeit hatte, verschiedene falsche Antworten zu geben. Außerdem kann die Menge an verschiedenen Antworten auch mithilfe der „temperature“ beeinflusst werden. Ein „temperature“ Wert kann für die Generierung einer Ausgabe übergeben werden, dieser Wert ist leider schlecht dokumentiert. Er beeinflusst aber generell die Zufallsverteilung mithilfe derer die Wörter ausgewählt werden. Ein extrem geringer Wert wird dafür sorgen, dass nur sehr wenig verschiedene Wörter für die Ausgabe genutzt werden, bei einem extrem hohen Wert besteht der erzeugte Text aus so vielen verschiedenen Wörtern, dass diese willkürlich zusammengewürfelt wirken. Ab etwa einem Wert von größer als 1 fängt die Grammatik langsam an negativ beeinflusst zu werden. In diesen Versuchen ist immer ein Wert von 0,7 genutzt worden.

Die zweite Frage war: „When did Pluto stop being a planet?“. Die erwartete Antwort wäre: „2006“. Dies ist die Frage mit mittlerer Schwierigkeit, hier darf man nicht von dem Satz „That all changed in the late 1990s[...]“ verwirrt werden. Die Antwort steht erst später im Text: „[...] ultimately decided in 2006 [...]“. Außerdem ist die Fragestellung absichtlich nicht mehr so eindeutig wie bei Frage 1. Die Ergebnisse sind in der Abbildung 12 zu sehen.




Abbildung 12: Vergleich der Antworten beider Modelle auf die Frage: „When did pluto stop being a planet?“

Das Ergebnis der zweiten Frage ist unerwartet. Paradoxerweise liefert das kleinere Modell 1 hier deutlich bessere Ergebnisse als, wie eigentlich zu erwarten gewesen wäre, das größere Modell 2. Modell 1 übertrifft, trotz der schwierigeren Fragestellung, mit 99% Genauigkeit sogar das Ergebnis aus Frage 1, wohingegen Modell 2 bei dieser Frage, im Gegensatz zur Frage 1, vollständig versagt. Die mit Abstand häufigste Antwort ist hier „late 1990s“ gefolgt von „1990“. In insgesamt 67% der Antworten fällt das Modell damit auf die zuvor beschriebene Schwierigkeit der Frage hinein. Nur 11% der Antworten sind „2006“ und damit korrekt. Die Erwartung beim Ausführen dieses Experiments war das genaue Gegenteil des tatsächlichen Ergebnisses. Daraus stellt sich nun die Frage: Wie kommt es zu diesem Ergebnis? Die einfachste Möglichkeit wäre folgende: Beim Finetuning des größeren 774M Modells ist es nötig, mehr Trainingsschritte zu machen als beim kleineren Modell um eine ähnliche Genauigkeit zu erreichen. Eigentlich sollte es zwar genau umgekehrt sein, dass

größere Modell braucht weniger Training als das kleinere, aber da auch der durchschnittliche Loss bei Modell 2 höher ist als bei Modell 1 bestand diese Theorie. Um diese Hypothese zu überprüfen, wurde Modell 3 mit 8000 Trainingsschritten erstellt. Bei der Eingabe der gleichen Aufgabe bestand allerdings weiterhin dasselbe Problem, was diese erste Theorie ausschließt. Bei der Recherche zu dieser Frage stößt man in Forendiskussionen und GitHub Issues immer wieder auf die Aussage das GPT-2 Schwierigkeiten hat mit Zahlen umzugehen. Das ist insofern interessant als das die Antworten auf Frage 2 ausschließlich Zahlen sind. Es ist allerdings nicht möglich, dies anhand einer offiziellen Aussage oder eines Artikels zu bestätigen. Somit scheint dies eher ein Gerücht zu sein als ein Fakt. Außerdem würde das nicht erklären, warum Modell 1 so viel besser ist als Modell 2. Hätte generell GPT-2 Probleme mit Zahlen wäre zu erwarten, dass die Ergebnisse beider Modelle unterdurchschnittlich sind, was aber nicht der Fall ist. Weitere Tests zu dem Thema deuten allerdings daraufhin, das Zahlen vielleicht tatsächlich etwas mit dem Problem zu tun haben könnten. Der erste Schritt im Versuch das Problem zu identifizieren war, das Testen anderer Fragestellungen, um herauszufinden, ob es sich hierbei um einen Einzelfall handelt oder nicht. Dabei ergaben die Tests mit anderen Texten anfänglich, dass es sich dabei tatsächlich um einen Einzelfall handeln müsse. Hier trat das Phänomen nicht auf. Bei erneuter Betrachtung des Kontextes für die Fragen, fiel auf, dass sich in dem Text tatsächlich überdurchschnittlich viele Zahlen befinden, egal ob in Ziffernschreibweise oder ausgeschrieben. Innerhalb der 3 Sätze des Kontexts befinden sich 5 Zahlen. Für einen Menschen wirkt das zwar unbedeutend, doch es ist möglich, dass dies weit genug vom Durchschnitt der Texte, mit denen GPT-2 entweder im Pre-Training oder im Finetuning trainiert wurde, abweicht, um das Modell zu verwirren. Dabei sei bemerkt das dies, mit dem Wissen darüber wie GPT-2 funktioniert, nur bedingt eine Erklärung für das zu erkennende Verhalten ist. In der Theorie sollte es egal sein, ob es sich bei einem Wort nun um eine Zahl oder ein beliebiges anderes Wort handelt. Ohne weitere Tests ist es an dieser Stelle schwierig, weitere Aussagen zu der Validität dieser Hypothese zu treffen.

Das gleiche Problem ist auch in Frage drei, „How many planets are in the solar system?“, zu finden. Die korrekte Antwort wäre „8“. Die Problematik dabei ist das am Anfang des Textes steht, dass es früher 9 Planeten im Sonnensystem gab. Erst im letzten Satz wird diese Aussage auf die heutige Anzahl an echten Planeten korrigiert. Versteht das Modell den Kontext nicht richtig, ist es also gut möglich, dass die Antwort „9“ gegeben wird. Die Ergebnisse sind in Abbildung 13 zu sehen.




Abbildung 13: Vergleich der Ergebnisse zu der Frage: „How many planets are in the solar system?“

2. Funktionsweise

Es zeigt sich der gleiche Trend wie schon bei Frage 2. Während das kleinere Modell 1 in 64% der Fälle die richtige Antwort gibt. Versagt Modell 2 erneut komplett und gibt in 92% der Fälle die falsche Antwort „9“. Nur in 4% der Fälle antwortet das Modell korrekt mit „8“.

Um die zuvor aufgestellte Theorie zu unterstützen, dass dieses Verhalten tatsächlich etwas mit der Anzahl an Zahlen im Kontext zu tun haben könnte, wurden zusätzlich noch weitere Tests durchgeführt, bei denen der Kontext besonders viele Zahlen beinhaltet. Beispielhaft sei hier noch einmal ein Test dargestellt.

Der Kontext für diesen Test ist folgender:

The first season is based to a large extent on the first volume of the book series Leviathan Awakening and was broadcast on Syfy from December 14, 2015 to February 2, 2016, with the first episode being released in advance as a stream on November 23, 2015. The second season, based on the rest of the first and part of the subsequent band Caliban's War, aired in the United States from February 1 to April 19, 2017. In Germany, it will be broadcast on Netflix from September 8, 2017. In March 2017, the extension of the series by a third season became known, which was broadcast in the USA from April 11 to June 27, 2018 and whose plot is based on parts of the second and the entire third volume.

Abbildung 14: Kontext für den zusätzlichen Test zur Überprüfung der Theorie. Quelle: Auszug aus dem Wikipedia Eintrag zu „The Expanse“ [23] (eigene Übersetzung ins englische)

Die Frage zu diesem Text war „When was the third season aired?“. Die Korrekte Antwort ist: „April 11 to June 27, 2018“ oder eine Variation davon. Wie zu sehen ist, sind in dem Text wieder eine Vielzahl an Zahlen zu finden, hauptsächlich, aber nicht ausschließlich, in Form von Daten. So soll überprüft werden, ob das Problem auch bei einem anderen Kontext auftritt, wenn dieser ebenfalls viele Zahlen enthält. Die in Abbildung 15 zu sehenden Ergebnissen bestätigen die Theorie. Modell 1 antwortet in 44% der Fälle korrekt. Wenn man Antwort zwei und drei noch mit dazu zählt, schließlich könnte man argumentieren das diese nicht wirklich falsch sind, antwortet das Modell sogar in 73% der Fälle richtig. Modell 2 hingegen antwortet nur 20% der Zeit korrekt, ist man auch hier wieder großzügig und zählt Antwort 3 dazu, sind es immerhin 39% der Fälle, in denen eine richtige Antwort gegeben wurde. In jedem Fall beantwortet das kleinere Modell 1 die Frage allerdings mehr als doppelt so häufig richtig wie Modell 2.




Abbildung 15: Vergleich beider Modelle anhand eines anderen Textes

Da dieses Phänomen bei anderen Tests mit Texten, ohne besonders viele Zahlen im Text, nicht aufzutreten scheint, ist es wahrscheinlich, dass Texte mit vielen Zahlen schlechter vom

größeren Modell 2 verstanden werden. Der wahrscheinlichste Fall ist es, dass der Datensatz in irgendeiner Art und Weise Texte mit vielen Zahlen benachteiligt, womöglich weil die Texte im Datensatz jeweils eher wenige Zahlen enthalten, wieso dies dann allerdings das kleinere Modell weniger betrifft als das größere Modell, erklärt sich damit nicht. Es wäre auch denkbar, dass im Fall des Größeren Modells eine Überanpassung („overfitting“) auf den Datensatz auftritt. Als Überangepasst beschreibt man in der Statistik ein Vorhersagemodell, welches während des Trainings zu genau auf den spezifischen Trainingsdatensatz angepasst wurde und deshalb schlechte Vorhersagen bei neuen Datensätzen trifft. [24] Aufgrund der Trainingszeit bzw. der Trainingsschritte der Modelle sowie der Größe des Datensatzes scheint das allerdings eher unwahrscheinlich. Außerdem sollte eine Überanpassung auf beiden Modellen Gleicherweise auftreten, schließlich wurden beide Modelle mit dem gleichen Datensatz und der gleichen Anzahl an Trainingsschritten erstellt. Theoretisch wäre es auch möglich, dass der Datensatz zu klein ist. Da dieser allerdings über 78.000 Aufgaben enthält, ist das auch fraglich.

Da GPT-2 wie alle anderen Machine Learning Modelle als Blackbox arbeitet, ist es schwierig, den genauen Grund für dieses Verhalten zu finden. Es ist möglich, dass die aufgestellte Hypothese stimmt und der SQUAD wirklich für das Verhalten verantwortlich ist. Genauso gut kann es aber auch sein, dass eine große Menge an Zahlen im Text nicht die Ursache des Problems ist, sondern die hier dokumentierten Probleme mit Zahlen nur ein Symptom eines anderen, zurzeit undefinierten, Problems darstellen.

Die bisher gezeigten Beispiele stellen eine sehr typische Aufgabe für Modelle wie GPT-2 dar. Dabei wurden bisher klassische Texte für das Training und die Eingaben verwendet. Da es in Kapiteln zur Anwendung von Texterzeugungsmodellen auch um abstraktere Beispiele gehen soll, ist es interessant, an dieser Stelle auch zu betrachten, wie GPT-2 mit abstrakteren Texten umgeht. Dazu soll dem Modell beigebracht werden, einfache Gleichung zu lösen. Gleichung eignen sich gut für dieses Experiment, das sie wohl zu den abstraktesten Texten gehören, außerdem ist es einfach, die Ergebnisse zu bewerten und zu vergleichen. Bei einfachen Gleichungen mit einer Variablen gibt es eben meist nur ein korrektes Ergebnis.

Wie zuvor ist der erste und wichtigste Schritt das Finden eines passenden Datensatzes. Das relativ bekannte Unternehmen DeepMind, welches mittlerweile zu Google gehört, stellt auf ihrem GitHub Konto (github.com/deepmind) das Repository „mathematics_dataset“ zur Verfügung, dieses ermöglicht es, auf eine große Anzahl an mathematischen Aufgaben zuzugreifen. Diese sind sortiert nach Trainingsschwierigkeit und Aufgabenart. Um die Trainingszeit im Rahmen zu halten und die Bewertung der Ergebnisse einfach zu machen, wurde für das Finetuning die Version „algebra_linear_1d“ aus dem Bereich „train-easy“ genutzt. Eine mögliche Aufgabe aus dem Datensatz wäre zum Beispiel diese: „solve $0 = -4*a - 24 + 12$ for a“. Anders als beim SQUAD ist hier das gegebene Format bereits eine Textdatei. Allerdings wurde auch hier eine Veränderung an der Formatierung des Datensatzes, mittels eines kurzen Python Skripts (auf GitHub: [src/formatMath.py](#)) vorgenommen. Dabei wurde die zuvor für den SQUAD genutzte Formatierung für diese Aufgabe adaptiert. Der Token „<|startoftext|>“ sowie „<|endoftext|>“ wurden unverändert übernommen. Für die Identifizierung der einzelnen Teile der Aufgaben wurden folgende Token eingesetzt: „[EQUATION]“ für die eigentliche Formel, „[SOLVEFOR]“ für die Variable, nach der die Gleichung gelöst werden soll und „[SOLUTION]“ für die Lösung der Gleichung. Ein vollständiger Aufgabenblock kann beispielhaft in Abbildung 16 gesehen werden.

2. Funktionsweise

```
<|startoftext|>
[EQUATION]: 0 = -4*a - 24 + 12
[SOLVEFOR]: a
[SOLUTION]: -3
<|endoftext|>
```

Abbildung 16: Beispielaufgabe für das Finetuning zum Lösen von Gleichungen

Beim Betrachten der Beispielaufgabe in Abbildung 16 könnte die Frage aufkommen, wozu die „[SOLVEFOR]“ Zeile dient. Schließlich ist diese bei Gleichungen mit einer einzigen Variablen überflüssig. Das Hauptziel der „[SOLVEFOR]“ Zeile ist es, dem Modell das Verstehen der Aufgabe so einfach wie möglich zu machen. Es wäre mit Sicherheit auch möglich, ein funktionierendes Modell, ohne diese Zeile zu erstellen, vermutlich würde dies allerdings deutlich mehr Trainingsschritte und damit mehr Trainingszeit benötigen. Des Weiteren wurde die Anzahl an Gleichungen im Trainingsdatensatz im Vergleich zum originalen Datensatz reduziert, um die Trainingszeit zu verringern. Der ursprüngliche Datensatz umfasst über 700.000 verschiedene Gleichungen. Der reduzierte Datensatz, der für die im folgenden vorgestellten Modelle genutzt wurde, beinhaltet nur noch 200.000 Gleichungen. Ähnlich wie bei den vorherigen Beispielen wurden zwei verschiedene Modelle trainiert die nun vorgestellt und verglichen werden.

1. Modell: Finetuning anhand der 355M Version von GPT-2 mit 4000 Trainingsschritten. Der durchschnittliche Loss betrug am Ende 0.49. Das Training fand mit Hilfe einer Nvidia Tesla P100 16GB statt und dauerte 61 Minuten.

2. Modell: Diesem Modell liegt die 774M Variante von GPT-2 zugrunde. Wie beim ersten Modell wurden hier 4000 Trainingsschritte durchlaufen. So konnte ein durchschnittlicher Loss von 0.48 erreicht werden. Wie auch beim ersten Modell wurde für das Training ein System mit einer Nvidia Tesla P100 16GB verwendet, welches 120 Minuten für die Aufgabe brauchte.

Um die Leistungsfähigkeit der Modelle überprüfen und vergleichen zu können, wurden beiden Modellen sieben verschiedene Gleichungen zum Lösen gegeben. Dabei sollte das Modell die Aufgaben jeweils 100-mal beantworten, um so eine Verteilung über die Antworten zu generieren und die Wahrscheinlichkeiten der verschiedenen Antworten vergleichen zu können. Da es sich bei den Antworten um einzelne Zahlen handelt, ist kein kreatives Schreiben in den Antworten gewünscht. Deshalb wurde für die Tests der „temperature“ Wert auf 0.2 reduziert. Die sieben Gleichungen und ihre erwarteten Lösungen sind in Tabelle 2 zu sehen.

Nr.	Gleichung	Lösen nach	erwartete Antwort
1	$10 = 5*x$	x	2
2	$-40 = 15*x + 5*x$	x	-2
3	$135 = 6*x + -4*x + 15$	x	60
4	$0 = 31*x - 336 + 119$	x	7
5	$x = 100 - 95$	x	5
6	$x = 100 + -95$	x	5
7	$10 = 2*x + 4$	x	3

2. Funktionsweise

Tabelle 2: Aufgaben und ihre Lösungen für die Tests zum Lösen von Gleichungen

Bei Betrachtung der verschiedenen Gleichungen können einige Besonderheiten auffallen:

1. Die Lösungen der Aufgaben sind immer Zahlen im Bereich -10 bis 10 mit der Ausnahme von Gleichung drei. Dies ist wichtig, da die Gleichungen im Datensatz nahezu ausschließlich Lösungen in diesem Zahlenbereich haben. Das bedeutet die Modelle haben nicht gelernt, höhere Zahlen als Antwort zu geben. Aufgabe drei dient als Test, ob die Modelle trotzdem in der Lage sind eine entsprechende Gleichung zu lösen, eine Korrekte Antwort ist hier allerdings nicht zu erwarten.

2. Alle Gleichung sollen nach der Variablen x aufgelöst werden. Im Datensatz werden die verschiedensten Buchstaben als Variablenname genutzt. Der Grund dafür, dass das hier nicht der Fall ist, besteht in der Vergleichbarkeit der Ergebnisse. Es ist möglich, dass bestimmte Buchstaben, innerhalb des Datensatzes, besonders häufig oder besonders selten als Variablennamen, genutzt werden. Durch die Nutzung der gleichen Variablenbezeichnung in allen Gleichungen wird sichergestellt, dass keine Aufgabe einen Vor- oder Nachteil gegenüber einer anderen hat.

3. Die Aufgaben 5 und 6 unterscheiden sich lediglich in der Schreibweise der Gleichungen. Während in Gleichung 5 direkt eine Subtraktion zweier Zahlen gefordert ist, wird in Gleichung 6 eine positive mit einer negativen Zahl addiert. Grundsätzlich sind beide Aufgaben damit gleich und es kommen beide Schreibweisen im Datensatz vor. Nichtsdestotrotz wird es interessant zu sehen, ob sich die Modelle von den unterschiedlichen Schreibweisen beeinflussen lassen.

In Abbildung 17 sind die Ergebnisse der Aufgaben von beiden Modellen zu sehen. Dabei ist jeweils dargestellt, wie viel Prozent der Antworten korrekt waren.




Abbildung 17: Vergleich der Lösungen für die Gleichungsaufgaben

Bei der Auswertung der Antworten werden Aufgaben nur dann als richtig beantwortet gezählt, wenn die korrekte Antwort mindestens den Schwellwert von 50% überschreitet. Das bedeutet, nur wenn mindestens 51 der 100 Antworten für eine Aufgabe die korrekte Lösung enthalten, zählt die Aufgabe als korrekt beantwortet. So soll verhindert werden, dass Aufgaben, bei denen sich ein Modell sehr unsicher ist, als korrekt klassifiziert werden. Theoretisch aber wären auch andere Bewertungsmethoden denkbar.

Unter den gerade beschriebenen Voraussetzungen beantworten beide Modelle jeweils vier der sieben Aufgaben korrekt. Unter Berücksichtigung des insgesamt eher kurzen Trainings sowie

der Abstraktheit dieser Aufgabe im Vergleich zu eher typischen Aufgaben für GPT-2, ist das ein gutes Ergebnis, insbesondere wenn man bedenkt, dass bei Aufgabe 3 auch keine richtige Antwort erwartet wurde.

Aufgabe drei, deren Lösung weit außerhalb der Lösungen des Datensatzes liegt, wurde wie erwartet von keinem der Modelle richtig beantwortet. Stattdessen gab das Modell 1 82-mal die Antwort „9“ und 18-mal die Antwort „7“, während Modell 2 in 100% der Fälle mit „5“ antwortet. Auch wenn die Antworten falsch sind, zeigt dies allerdings gut einen Grundaspekt, nicht nur von GPT-2, sondern aller Machine Learning Modelle: die Ausgabe und damit ihre Möglichkeit, Aufgaben zu lösen beschränkt sich immer auf das mithilfe von Datensätzen trainierte Wissen. In diesem Fall sind im Datensatz keine Lösungen größer 10 vorhanden, also kommt für die Modelle eine Lösung wie „60“ gar nicht in Frage.

Auch der Spezialfall von Aufgabe fünf und sechs zeigt eine Besonderheit. Beide Modelle lassen sich tatsächlich von den unterschiedlichen Schreibweisen verwirren und beantworten jeweils nur eine der beiden Aufgaben richtig. Interessanterweise unterscheiden sich die Modelle allerdings darin, welche der Aufgaben richtig beantwortet wird. Während Modell 1 Aufgabe fünf richtig beantwortet, aber nicht Aufgabe sechs, ist es bei Modell 2 genau umgekehrt. Interessant ist dabei aber auch das die jeweils die Antworten sind, bei denen sich die Modelle am unsichersten sind, Modell 1 gibt bei Aufgabe sechs in 43% der Fälle die richtige Antwort und schafft es damit nur knapp nicht den Schwellwert zu überschreiten, um als korrekt beantwortet zu gelten. Im Vergleich ist Modell 2 bei Aufgabe fünf mit 26% richtigen Antworten zwar nicht so knapp vor dem Schwellwert, gibt aber dennoch signifikant oft die richtige Antwort. Bei den anderen Aufgaben sind sich die Modelle meist sehr sicher, ob die Antwort nun richtig ist oder nicht. Dabei scheint Modell 2 bei dieser Aufgabe aber vor allem ein Problem mit dem Vorzeichen zu haben, denn während des Modells in nur 26% der Fälle korrekt mit „5“ antwortet, gibt das Modell in 69% der Fälle die Antwort „-5“ und macht somit lediglich einen Vorzeichenfehler.

Wundersam ist außerdem das beide Modelle bei Aufgabe sieben komplett versagen. Anders als die Aufgaben drei, fünf und sechs war diese Aufgabe nicht darauf ausgelegt einen Fehler zu provozieren, im Gegenteil, nach den schwierigeren Aufgaben fünf und sechs sollte diese Aufgabe lediglich noch einmal einen einfach zu lösenden Abschluss darstellen. Warum die Modelle hier Probleme haben, lässt sich ohne weiteres nicht sagen.

Alles in allem kann man sagen, dass beide Modelle die Aufgabenstellung „Gleichungen lösen“ relativ gut bewältigen konnten. Das Problem aus den ersten Beispielen scheint sich hier nicht wiederzufinden, was weiter darauf hinweist, dass das Problem dort im Datensatz lag. Allerdings ist hier auch keine Verbesserung beim Wechsel auf das größere Modell festzustellen. Vermutlich wären mehr Tests und längeres Training nötig, um die Vorteile des größeren Netzes zu bemerken. Verschiedene Artikel und Forendiskussionen deuten darauf hin, dass die größeren Modelle, insbesondere im Bereich „Kreatives Schreiben“, auch schon bei kleineren Datensätzen deutlich Vorteile gegenüber den kleineren Modellen bieten. Da sich die Ausgaben in diesem Aufgabenbereich allerdings nur schwer objektiv bewerten lassen und damit auch nur schlecht zu vergleichen sind, wurden in diesem Aufgabenbereich keine weiteren Tests durchgeführt.

2.2.3. Schlussfolgerungen aus den Programmbeispielen

Die verschiedenen Programmbeispiele helfen zu zeigen, dass nicht nur die Theorie neuronaler Netze komplex ist. Auch bei der praktischen Anwendung gilt es verschiedene komplexe Aspekte zu verstehen, wenn auch der eigentliche Code, zumindest im Fall von gpt-2-simple, nicht besonders aufwendig zu schreiben ist. Bei der Auswertung der Beispiele ist es wichtig zu bedenken, dass die Experimente nur einen kleinen Bereich der theoretischen Möglichkeiten von GPT-2 abdecken und mit GPT-3 bereits ein leistungsfähigeres Modell existiert, auch wenn der Zugang zu diesem beschränkt ist. Zusätzlich ist es wichtig zu beachten, dass mithilfe einiger weniger Beispiele keine Schlussfolgerungen für das GPT-2 Modell oder gar die GPT-Reihe im Allgemeinen möglich sind. Die im Folgenden dargestellten Schlussfolgerungen sind einzig ein Produkt der während der Experimente gemachten Erfahrungen und damit nicht unbedingt repräsentativ für andere Modelle oder Aufgabenbereiche.

Eine der ersten Erfahrungen im Umgang mit GPT-2, noch vor der ersten tatsächlichen Verwendung des Modells war, dass die Hardwareanforderungen für die Nutzung des Modells enorm hoch sind, insbesondere bei den größeren Modellen.

Für die Ausführung wurden insgesamt drei verschiedene Hardwarelösungen genutzt:

System 1: Lokale Hardware mit einem Intel Core i7-8700K, einer Nvidia 1080 Ti mit 11GB GPU-Speicher und 16GB Arbeitsspeicher.

System 2: Google Colaboratory VM mit einem Kern und zwei Threads eines Intel Xeon Prozessors, einer Nvidia Tesla T4 mit 16GB GPU-Speicher und etwa 12GB Arbeitsspeicher.

System 3: Google Colaboratory Pro VM mit zwei Kernen und vier Threads eines Intel Xeon Prozessors, einer Nvidia Tesla P100 mit 16GB GPU-Speicher und etwa 24GB Arbeitsspeicher.

Der anfängliche Plan bestand darin, die Experimente lokal auf System eins durchzuführen. Dabei viel allerdings schnell auf, dass dies nicht funktionieren würde. Zwar ist die Hardware von System 1 für die meisten, auch aufwendigeren, Aufgaben performant genug, doch selbst das Training eines 355M Modells war sehr langsam während bei größeren Modellen der Grafikspeicher von 11GB nicht ausreichte, um diese zu trainieren. Aus diesem Grund war der Umstieg auf Google Colaboratory nötig. Wobei hier anfänglich auf die kostenfreie Version zurückgegriffen wurde, welche von System 2 repräsentiert wird. Mit dieser Hardware ist das Finetuning eines 355M Modells problemlos möglich, während das Training mit der 774M Variante von GPT-2 je nach Datensatz und Trainingseinstellungen nicht immer erfolgreich war. Im Versuch das Finetuning von 774M Modellen zuverlässiger zu machen und das Training eines 1558M Modells zu ermöglichen, fand schließlich ein letztes Hardwareupgrade, durch die Nutzung von Google Colaboratory Pro, statt. Diese wird in System 3 dargestellt. Im Vergleich zu System 2 wird hier die deutlich schnellere Nvidia Tesla P100 sowie die doppelte Menge an Arbeitsspeicher verwendet. Während das Training mit dem 774M Modell hier nun zuverlässig funktioniert, war selbst mit diesem System das Training eines 1558M Modells nicht möglich. Das Training der 355M Modelle mit 4000 Trainingsschritten dauerte hier jeweils etwa eine Stunde, während das Training der 774M Modelle bei 4000

Trainingsschritten etwa die doppelte Zeit benötigte. Selten ist es mit Colaboratory Pro auch möglich, Zugriff auf eine Nvidia Tesla V100 16GB zu erhalten, welche im Vergleich zur P100 noch einmal deutlich mehr Leistung bietet, so dass das Training eines 774M Modells mit 8000 Trainingsschritten etwa die gleiche Zeit beansprucht wie das Training eines Modells mit 4000 Trainingsschritten mit der langsameren Nvidia Tesla P100. Aber auch damit war das Training eines 1558M Modells nicht möglich. Das Problem liegt hier in dem nicht ausreichenden Grafikspeicher von 16GB. Die Tesla V100 gibt es auch als 32GB Version, mit dieser wäre es vermutlich möglich das größte GPT-2 Modell zu verwenden. Der Zugriff auf entsprechende Hardware ist allerdings, insbesondere für Privatpersonen und ohne große Budgets, schwierig.

Eine weitere wichtige Erfahrung aus den Experimenten ist, wie wichtig es ist, Erfahrung mit den Modellen zu haben, um die besten Ergebnisse zu erzielen. Auf der einen Seite sind viele Aspekte der Nutzung von GPT-2 eher schlecht dokumentiert. Auf der anderen ist das Finden der richtigen Einstellungen für das Finetuning und für die Ausgabe sehr wichtig, um gute Ergebnisse zu erzielen. „Wie hoch sollte die `learning_rate` sein?“, „Was ist die beste `batch_size`?“, „Welcher optimizer ist der Beste?“, „Wie viele Trainingsschritte eignen sich am besten?“ und weitere Fragen stellen sich bei den ersten Versuchen ein Modell zu trainieren. Da sich die Antworten auf diese Fragen von Modell zu Modell und Datensatz zu Datensatz unterscheiden, hilft Recherche an dieser Stelle nur bedingt. Hier sind Erfahrungswerte mit GPT-2 oder ähnlichen Modellen gefordert, stellenweise ist es allerdings möglich in Foren, wie zum Beispiel StackOverflow (stackoverflow.com), die Erfahrungswerte anderer kennenzulernen. In den Programmbeispielen wurden viele dieser Einstellungen ganz einfach auf dem, von `gpt-2-simple` vorgeschlagenen, Standardwerten belassen. Das Verwenden dieser Modelle ist kein einfaches „Plug and Play“, um die besten Ergebnisse zu erzielen, sollten diese Einstellungen auf die spezifische Situation angepasst werden.

Die Experimente lassen außerdem eine Vermutung aufkommen: Im Internet sieht man immer wieder Werbung oder Artikel, die extrem gute Resultate von Maschine-Learning-Modellen vorstellen. Es scheint unwahrscheinlich, dass dies immer direkt die erste Ausgabe bzw. der erste Versuch des Modells ist. Vielmehr sind viele dieser, oft beeindruckenden, Präsentationen wohl nur die besten Ergebnisse, die das Modell erzeugen konnte. Bei GPT-2 ist es zum Beispiel sehr einfach, sich 10, 100 oder 1000 Ausgaben zur gleichen Aufgabe generieren zu lassen, dann die Beste auszuwählen und nur diese zu präsentieren ist einfach. Aus diesem Grund wurden in den Programmbeispielen auch immer 100 Ausgaben generiert und verglichen. Eine einzige Ausgabe ist nicht repräsentativ für die Leistung eines Modells. Das zeigt sich zum Beispiel gut im Beispiel zum Thema „verstehendes Lesen“, als Probleme mit dem größeren Modell auftraten, wäre es einfach gewesen, eine andere Aufgabe zu präsentieren. Dabei ist zu beachten das bessere Modelle, wie zum Beispiel GPT-3, natürlich immer bessere Ergebnisse liefern, aber auch hier wird nicht jede Ausgabe immer direkt dem entsprechen, was sich vom Nutzer gewünscht wurde.

Die letzte und wohl wichtigste Erfahrung ist die Notwendigkeit guter Datensätze und die Schwierigkeit, Probleme in einem Modell zu lösen. Ein Mensch kann mithilfe von Logik frühere Erfahrungen und gelernte Informationen verknüpfen, um neue Aufgaben und Situationen zu meistern. Ein Maschine-Learning-Modell im Gegensatz, muss sich immer auf, aus den Datensätzen gelernte, Aspekte beziehen. Weicht eine Aufgabe zu weit von den Datensätzen ab, verschlechtern sich die Ergebnisse dramatisch, dies ist beispielhaft in den

2. Funktionsweise

Experimenten zur Lösung mathematischer Gleichungen zu sehen. Umgekehrt kann es, aufgrund der Blackbox-Struktur, teilweise sehr schwer oder sogar unmöglich sein, herauszufinden, wieso ein Modell eine bestimmte Antwort gibt. Was insbesondere dann zu einem Problem wird, wenn die Ausgaben des Modells von den erwarteten oder gewünschten Ergebnissen abweichen. Um am Ende gute Ergebnisse zu erzielen, sind sehr umfangreiche Datensätze sowie eine Vielzahl an Tests nötig.

3. Anwendungsmöglichkeiten

Nachdem die Funktionsweise sowie theoretisch als auch praktisch untersucht wurde, wird es in diesem Kapitel nun Zeit, den Fokus auf die möglichen Anwendungsbereiche von Texterzeugungsmodellen zu legen. Dabei werden zuerst kurz einige Anwendungsfälle allgemein besprochen und schließlich zwei mögliche Anwendungen gewählt, die genauer untersucht werden. Dabei werden einerseits die beiden Anwendungsfälle genauer geschildert, wobei auch die Technische Umsetzung miteinbezogen wird, und andererseits auch auf mögliche Probleme eingegangen wird, welche sich in den Anwendungsfällen präsentieren. Dabei beschränkt sich die Diskussion der Probleme vorerst auf Probleme technischer Art. Probleme, die auf rechtlichen oder ethischen Aspekten beruhen, werden später in Kapitel 4. „Risiken“ behandelt.

Im Allgemeinen sind Anwendungsmöglichkeiten von Texterzeugungssystemen überall dort zu finden, wo in irgendeiner Art und Weise mit Text gearbeitet wird. Da dies die Anwendungsbereiche allerdings nicht wirklich einschränkt, ist es wichtig, hier die technischen Möglichkeiten sowie die mögliche Arbeitersparnis einzubeziehen. Steht in einem Anwendungsfall zum Beispiel ein hoher technischer Aufwand einer geringen Ersparnis gegenüber, besteht dieser Anwendungsfall nur in der Theorie hat aber keine Praktische Relevanz. Dabei ist auch zu bedenken, dass diese Einschätzung subjektiv ist und sich die Linie zwischen theoretischen- und praktisch relevanten Möglichkeiten, mit voranschreitenden technischen Möglichkeiten, verschiebt.

Ein Beispiel für eine Anwendungsmöglichkeit die, aufgrund ihrer potenziell sehr großen Nutzerbasis, einen großen Nutzen bringen könnte, ist die Verbesserung und Erweiterung von Autokorrektur-Software, zum Beispiel auf dem Smartphone. Natürlich werden dafür auch heute schon Machine-Learning-Modelle genutzt und viele dieser Modelle sind auch bereits in der Lage, neben der Eigentlichen Korrekturfunktion, die folgenden Wörter vorzuschlagen. Damit könnten diese Modelle bereits dem Bereich der Texterzeugungssysteme zugeordnet werden. Sie unterscheiden sich aber von den bisher besprochenen Texterzeugungssystemen wie GPT, durch ihre Größe und Leistung. Die Nutzung eines großen Modells wie GPT-3 innerhalb einer Autokorrektur-Software würde es ermöglichen, die Leistung, nicht nur der eigentlichen Korrekturen, sondern insbesondere auch, beim Vorschlagen von folgenden Wörtern zu verbessern. Ein Modell wie GPT-3 wäre sogar in der Lage, unter Einbeziehung der vorherigen Nachrichten, ganze Sätze vorzuschlagen. Eine solche Software wäre auch auf anderen Systemen, zum Beispiel am Computer nützlich. Allerdings gibt es einen guten Grund, warum solche Modelle nicht bereits für diesen Zweck genutzt werden. Diese Modelle benötigen schlicht zu viel Leistung. Welche, insbesondere auf Mobilgeräten, einfach nicht zur Verfügung steht, hier muss vor allem auch bedacht werden, dass die Vorschläge einer solchen Software nur dann Arbeit und Zeit sparen, wenn diese in Echtzeit, während des Schreibens eines Textes gegeben werden. Hier wäre die Arbeitersparnis zwar erheblich, der technische Aufwand allerdings noch ungleich höher.

Viele Anwendungsmöglichkeiten gehen in eine ähnliche Richtung wie soeben beschrieben. Im Bereich „Unterstützung beim Schreiben von Texten“ lassen sich viele Ideen Finden. So wäre zum Beispiel auch denkbar ein Modell auf das Schreiben von Business-E-Mails zu trainieren. Auch denkbar wäre eine Software die mittels eines Texterzeugungsmodells, Menschen dabei hilft, Bewerbungen zu schreiben. Diese Art von Aufgaben spiegelt sehr typische Anwendungsmöglichkeiten wider.

3. Anwendungsmöglichkeiten

Ein anderes Beispiel für einen Aufgabenbereich für die Texterzeugungsmodelle genutzt werden können, ist: Übersetzung. Dabei ist nicht in erster Linie eine Übersetzung, zum Beispiel vom Deutschen ins Englische (oder ähnliches) gemeint, auch, wenn auch dies problemlos umsetzbar wäre. Viel eher ist die Übersetzung eines normalen Satzes in Computersprachen. Zum Beispiel wäre eine Software denkbar die eine als Satz formulierte Anfrage in ein SQL-Statement übersetzt und dem Nutzer dann das Ergebnis anzeigt. Das könnte dann zum Beispiel so aussehen:

Eingabe: Zeige mir die Namen aller Nutzer, die in Deutschland wohnen und unter 25 Jahre alt sind.

Ausgabe: `SELECT name FROM users WHERE country='germany' AND age<25;`

Auch denkbar wäre das Ganze als eine Art Suchmaschine zu gestalten. Die Nutzern, die sich nicht gut mit SQL auskennen, helfen kann, eine sinnvolle Anfrage zu stellen. Natürlich muss sich dabei auch nicht auf SQL beschränkt werden. Das gleiche Konzept wäre auf für den Bereich Linux Terminal Befehle und noch viele andere Dinge denkbar.

Das Problem bei diesem Anwendungsfall ist allerdings auch recht offensichtlich: Der Großteil der Nutzer eines solchen Produkts wären vermutlich Menschen, die sich nicht gut mit der entsprechenden Syntax auskennen. Somit wäre es für die Nutzer nahezu unmöglich, Fehler der Software zu bemerken. Selbst erfahrene Nutzer könnten in langen Statements sehr leicht einen Fehler übersehen, was insbesondere in kritischen Situationen zu großen Problemen führen kann.

Eine weitere Möglichkeit Texterzeugungssysteme zu nutzen ist das Zusammenfassen und Durchsuchen von Texten. Wie in den Programmbeispielen gezeigt, kann GPT-2 (und auch GPT-3) Texte nach Antworten auf vom Nutzer gestellte Fragen durchsuchen. In Kombination mit der Möglichkeit Texte mittels eines Texterzeugungsmodells zusammenzufassen, ergeben sich so eine Vielzahl an Möglichkeiten. Denkbar ist zum Beispiel eine Suchmaschine, die statt Links zu Internetseiten direkt die Antwort auf eine Frage gibt, indem sie die gefundenen Texte zusammenfasst und dann darstellt. Allerdings ist dabei die Qualität der Antworten immer in Frage zu stellen.

Die Fähigkeit des Zusammenfassens und Durchsuchen von Texten ist auch für Unternehmen interessant. Hier wäre es möglich, mithilfe einer entsprechenden Software, Nutzerfeedback gezielt nach Informationen zu durchsuchen und die Meinung vieler Nutzer zusammengefasst angezeigt zu bekommen, anstatt alle Bewertungen einzeln lesen zu müssen. Dies könnte einer Firma enorm helfen eine große Anzahl an Bewertungen sinnvoll auszuwerten. Tatsächlich gibt es mit „Viable“ (askviable.com) bereits eine Software, die mithilfe von GPT-3 genau das versucht. „Viable“ versucht eine gestellte Frage anhand aller Bewertung zu beantworten und stellt dann eine Zusammenfassung, aber auch die verschiedenen Bewertungen, die sich mit der Frage beschäftigen, dar.

An der Vielzahl von verschiedenen dargestellten Ideen, ist zu erkennen, dass die theoretischen Anwendungsmöglichkeiten von Texterzeugungsmodellen nahezu endlos sind. Eine ausführliche Diskussion aller Anwendungsmöglichkeiten ist kaum möglich. Deshalb werden im Folgenden, wie zuvor angekündigt, zwei Anwendungsmöglichkeiten gewählt, um diese genauer diskutieren zu können.

3.1 Anwendungsmöglichkeit 1: Automatische Quellcode-Generierung

Wie im Programmbeispiel zum Thema Algebra gezeigt wurde, können Texterzeugungsmodelle auch auf abstraktere Texte trainiert werden. Nutzt man nun Quellcode als Trainingsdatensatz, ist es dementsprechend auch möglich, einem Texterzeugungsmodell beizubringen, Code zu schreiben. In diesem Kapitel wird diese Möglichkeit genauer diskutiert, dabei werden zwei verschiedene Ansätze der Automatische Quellcode Generierung unterteilt.

1. Verbesserte automatische Vervollständigung. Die meisten IDEs und Code Editoren bieten bereits seit längerem Vervollständigungsvorschläge an. Diese sind allerdings häufig nur sehr beschränkt. Mittels eines Texterzeugungsmodells wie GPT, könnten diese deutlich verbessert werden

2. Generierung ganzer Codeteile (Funktionen, Klassen, ...). Dies ist in etwa vergleichbar mit dem zuvor gebrachten SQL-Beispiel. Aufgrund einer Texteingabe werden ganze Funktionen oder sogar mehrere Funktionen automatisch generiert.

Die beiden Ansätze unterscheiden sich in einigen entscheidenden Punkten. So zum Beispiel die schon oft angesprochene benötigte Leistung. Obwohl 2. deutlich beeindruckender wirkt, schließlich werden hier ganze Funktionen vom Modell geschrieben, stellt dies, aus Performance-Sicht, aktuell denn deutlich realistischeren Ansatz dar. Da hier, auf Basis einer Texteingabe, mehrere Codezeilen auf einmal erzeugt werden, ist es nicht problematisch, wenn die Erzeugung des Codes ein oder zwei Sekunden dauert. Entsprechende Hardware vorausgesetzt, ist dies kein unrealistisches Ziel. Ansatz 1. Hingegen funktioniert mehr, wie die normale Autovervollständigung, die heutzutage sehr verbreitet ist, nur eben mit relevanteren Vorschlägen. Aus Sicht der Performance stellt dies allerdings ein Problem dar. Hier werden eben nicht ganze Funktionen erzeugt, sondern maximal eine Zeile vervollständigt. Das bedeutet, dass hier die Erzeugung des Codes in Echtzeit gesehen muss, um den Arbeitsfluss nicht zu unterbrechen. Benötigt ein solches System mehrere Sekunden für einen Vervollständigungsvorschlag ist es schneller für den Nutzer, die Zeile einfach selbst zu schreiben.

Die Entwicklung einer verbesserten automatischen Vervollständigung die große Texterzeugungsmodelle wie GPT-3 in Echtzeit nutzen kann, bietet allerdings eine sehr große potenzielle Zeit- und Arbeitsersparnis für Softwareentwickler. Nicht nur das die Relevanz der Vorschläge erhöht werden könnte, es wäre auch möglich die Vorschläge über einfache Variablen- und Funktionsnamen-Vervollständigung hinaus zu erweitern. So wäre es zum Beispiel denkbar, dass zusätzlich zum Funktionsnamen auch gleich passende Übergabeparameter vorgeschlagen werden oder beim Schreiben von if-Verzweigungen gleich passende Bedingungen vorgeschlagen werden. Dies sind nur zwei Beispiele wie ein solches System Arbeitszeit sparen könnte. Dabei ist vor allem auch zu bedenken, dass ein solches System kaum Einarbeitungszeit benötigen würde, viele Menschen nutzen heute beim Programmieren bereits entsprechenden Assistenz-Systeme. Der Arbeitsablauf würde sich somit nicht ändern. Es stellt sich dabei allerdings die Frage, ob die hier genannten Verbesserungen nicht auch ohne die Verwendung eines komplexen und leistungshungrigen Texterzeugungsmodells umsetzbar sind. Da es sich hier um vergleichsweise einfache Aufgaben handelt, ist es vermutlich auch möglich, diese mit einfacheren und performanteren Algorithmen zu lösen. Hier muss bedacht werden, dass, nur weil es möglich ist ein Problem mit Machine-Learning-Modellen zu lösen, dies nicht immer die beste Lösung ist.

3. Anwendungsmöglichkeiten

Die praktische Relevanz dieser Anwendungsmöglichkeiten, insbesondere von Ansatz 2. ist hoch. Während der Vorbereitung auf diese Arbeit wurde „GitHub Copilot“ vorgestellt. Ein System, das wie in 2. beschrieben helfen soll, Code zu schreiben, indem es, basierend auf Eingaben vom Nutzer, eigenständig Funktionen schreiben kann. Microsoft, denen GitHub gehört, hat vor einiger Zeit die Zusammenarbeit mit OpenAI aufgenommen, „GitHub Copilot“ ist eines der ersten Produkte das dieser Zusammenarbeit entstammt. „GitHub Copilot“ nutzt das „OpenAI Codex“ Modell welches wiederum auf GPT-3 basiert. „OpenAI Codex“ nutzt neben den von GPT-3 übernommenen Daten, eine große Menge an frei verfügbarem Quellcode, vermutlich in erster Linie GitHub, fürs Training. Leider ist der Zugriff auf „GitHub Copilot“ nur über eine Warteliste möglich, so dass eigene Tests mit der Software nicht möglich waren.

In Abbildung 18 ist ein Beispiel für die Funktionsweise von „GitHub Copilot“ zu sehen. Der grau unterlegte Teil des Codes wurde automatisch generiert. Der Code wurde in TypeScript geschrieben.

```
#!/usr/bin/env ts-node

import { fetch } from "fetch-h2";

// Determine whether the sentiment of text is positive
// Use a web service
async function isPositive(text: string): Promise<boolean> {
  const response = await fetch(`http://text-processing.com/api/sentiment/`, {
    method: "POST",
    body: `text=${text}`,
    headers: {
      "Content-Type": "application/x-www-form-urlencoded",
    },
  });
  const json = await response.json();
  return json.label === "pos";
}
```

Abbildung 18: Quellcode Beispiel von „GitHub Copilot“ [25]

Wie zu sehen ist wurde ein Import, ein Kommentar, der die Funktion beschreibt, und die Funktionssignatur vorgegeben. Die eigentliche Funktion wurde dann vom Modell generiert. Interessant ist dabei, dass Copilot in der Lage war das „fetch-h2“ Paket zu benutzen, obwohl dieses kein Standardpaket von TypeScript ist, auch in anderen Beispielen die auf der „GitHub Copilot“ Webseite zu finden sind wird die Fähigkeit präsentiert auch Pakete und APIs zu benutzen die nicht standardmäßig vorhanden sind. Vermutlich nimmt die Codequalität stark ab, wenn es sich um weniger genutzte Pakete oder APIs handelt.

Ein weiteres Problem, das es zu lösen gilt, ist die Aufrechterhaltung der Codequalität über verschiedene Programmiersprachen hinweg. Es ist davon auszugehen, dass das Modell ein gutes Verständnis von beliebten und damit viel verwendeten Programmiersprachen wie JavaScript oder Python hat. Wie gut, die Ergebnisse bei weniger verwendeten Programmiersprachen wie Rust, Lua, Kotlin oder einer der vielen anderen Sprachen, die auf GitHub weniger als ein Prozent der Codebasis ausmachen, sind, ist fraglich. GitHub selber sagt das Copilot besonders gut in den Sprachen Python, JavaScript, TypeScript, Ruby, und Go funktioniert, alles beliebte Programmiersprachen, deren Codebasis in den Trainingsdaten

vermutlich groß ist. Allerdings gibt es auch einige andere Programmiersprachen, die sehr beliebt sind, wie Java oder C++, die GitHub allerdings nicht speziell als gut funktionierend aufzählt. Ob das daran liegt, dass die Ergebnisse hier schlechter sind, oder sie einfach nur nicht genannt wurden, ist ohne weitere Tests, unklar. Neben der schieren Menge an Codebeispielen in den Trainingsdaten spielt noch eine andere Variable eine wichtige Rolle für die Codequalität des, von einem solchen Modell erzeugten, Quellcodes: die Codequalität des Codes im Datensatz. Beim Trainieren eines Modells für diesen Anwendungszweck ist es wichtig, darauf zu achten, dass die Codequalität hoch ist, um zu vermeiden, dass das Modell schlechten Code als Ausgabe erzeugt. Im Fall von Copilot ist es besonders wichtig, auf die Codequalität zu achten da hier in erster Linie der Code von GitHub als Datensatz genutzt wird. Da allerdings jeder ohne weitere Einschränkungen seinen Code veröffentlichen kann, ist die Codequalität hier im Durchschnitt vermutlich eher schlecht. Hier ist es wichtig entsprechende Beispiele aus dem Datensatz herauszufiltern. Insbesondere da hier die Beliebtheit von Programmiersprachen wie JavaScript oder Python dafür sorgen können, dass es bei diesen Sprachen auch besonders viel Code gibt, dessen Qualität schlecht ist, da Programmieranfänger mit hoher Wahrscheinlichkeit mit einer beliebten und weit verbreiteten Sprache anfangen und so zu einer großen Menge an eher schlechtem Code beitragen. Ein weiteres Problem kann sich aus daraus ergeben, für welchen Zweck eine Programmiersprache häufig genutzt wird. Eine Skriptsprache wie Python hat für den Nutzer den großen Vorteil dass es einfach und schnell ist, ein einfaches Programm zu schreiben das eine sehr bestimmte Aufgabe übernimmt. Dabei spielt allerdings zumeist die Codequalität eine untergeordnete Rolle, hier kommt es mehr darauf an, möglichst schnell Funktionierenden Code zu schreiben. Ein gutes Beispiel dafür sind die Skripte für das Formatieren der Daten für die Programmbeispiele aus Kapitel 2.2.3. diese sind in Python geschrieben, da Python es ermöglichte, sehr schnell ein funktionierendes Skript zu schreiben welches die, alles in allem recht einfache, Aufgabe der Textformatierung übernimmt. Die Code Qualität dieser Skripte ist nicht besonders gut, das war aber eben auch nie das Ziel, diese Skripte umfassen jeweils nicht mehr als 30 Zeilen, sie müssen in der Zukunft nicht gewartet werden, sie funktionieren heute und das ist alles was in diesem Fall zählt. Im Gegensatz dazu sind Projekte die in Sprachen wie Java oder auch Go geschrieben werden, in der Regel deutlich umfangreicher, sie umfassen oft tausende Codezeilen. In einem Solchen Projekt spielen Aspekte wie Wartbarkeit und Codequalität eine deutlich wichtigere Rolle. Natürlich gibt es auch kleine Projekte mit schlechter Codequalität in Java genauso wie große Projekte in Python bei denen stark auf die Qualität des Codes geachtet wird. Nimmt man allerdings den durchschnitt über alle Projekte hinweg, ist es wahrscheinlich, dass die unterschiedliche Nutzung verschiedener Programmiersprachen die Codequalität beeinflusst. Dabei ist auch zu bedenken, dass eine verbreitete Nutzung entsprechender Systeme, zur Replikation von Bugs, über eine Vielzahl von Programmen hinweg, führen kann.

Besonders wichtig ist die Codequalität, wenn man die Einsatzbereiche solcher Software bedenkt. Einer der großen Vorteile, die ein solches System liefert, ist es den Einstieg ins Programmieren für Anfänger enorm zu erleichtern. Indem es interaktive Quellcode Beispiele erzeugen kann, welche Anfängern helfen können verschiedene Aspekte der Softwareentwicklung zu erlernen, für die sie sich interessieren. Das Problem damit ist allerdings, dass ein Anfänger Schwierigkeiten haben wird Probleme zu erkennen und so potenziell anhand von fehlerhaftem Code lernt.

3. Anwendungsmöglichkeiten

Erfahrene Programmierer können die Fehler im Code zwar erkennen, diese werden aber vermutlich auf den Einsatz von Software wie Copilot in vielen Situationen eher verzichten, da es für sie in der Regel schneller sein wird, die entsprechenden Funktionen selbst zu schreiben. Es sei denn, sie müssen eine unbekannte Softwarebibliothek nutzen oder in einer ihnen fremden Programmiersprache schreiben. Hier ersetzt ein solches System mehr oder weniger einen Besuch auf StackOverflow. In diesem Fall kann allerdings auch ein erfahrener Softwareentwickler leicht Probleme übersehen, auch wenn dieser Probleme aufgrund seiner Erfahrung leichter erkennen und lösen kann.

Nachdem nun mehrfach die Fehleranfälligkeit als großes Problem genannt wurde, ist es interessant zu wissen, wie hoch diese auf dem Aktuellen Stand der Technik, im Fall von „GitHub Copilot“, ist. Betrachtet man die Internetseite auf der „GitHub Copilot“ aber auch „OpenAI Codex“ vorgestellt werden sieht man eine Vielzahl an Teilweise durchaus beeindruckenden Beispielen. Dies lässt allerdings einen etwas verfälschten Eindruck entstehen. Deutlich weiter unten auf der Webseite im FAQ im Bereich „General“ findet sich eine Angabe über die tatsächliche Leistung der Software. Dabei gab das Modell in von GitHub durchgeführten Tests in 43% der Fälle beim ersten Versuch den richtigen Vorschlag. Gibt man dem Modell bis zu 10 Versuche den richtigen Code vorzuschlagen, erhöht sich dieser Prozentsatz auf 57% [25]. Bedenkt man das sich Copilot zum Zeitpunkt des Schreibens dieser Arbeit im Status der „Technical Preview“ befindet, sind diese Ergebnisse durchaus beachtlich. Wird allerdings der Maßstab einer fertigen Softwarelösung angelegt, die in der echten Welt ihre Nutzer bei der Arbeit unterstützen soll, sind diese Zahlen weniger beeindruckend. Ein System, das in nur etwa 2 von 5 Fällen den richtigen Vorschlag liefert, ist in einem echten Produktionsumfeld wenig hilfreich. Dies zeigt, dass nach wie vor einige Arbeit nötig ist, bevor die echte Leistung eines solchen Modells das theoretisch mögliche Potential entsprechender Software ausschöpft.

Ein perfekt funktionierendes System, das keine Fehler macht, vorausgesetzt, bietet diese Anwendungsidee einen enormen Vorteil sowie für Anfänger als auch für erfahrene Programmierer. Bedenkt man den aktuellen Stand der Technik, stellt ein System wie „GitHub Copilot“ ein nützliches Tool für Programmieranfänger oder erfahrene Programmierer, die sich mit ihnen unbekannten Technologien beschäftigen wollen, dar, bei dem allerdings immer die, noch sehr hohe, Fehlerrate des der Software bedacht werden muss.

3. Anwendungsmöglichkeiten

3.2 Anwendungsmöglichkeit 2: Automatische Erzeugung von Nachrichtenartikeln

Eine der großen Stärken von Texterzeugungsmodellen wie GPT-3, ist dass sie automatisch auch längere, grammatikalisch korrekte und für den Leser sinnvolle, Texte generieren können und das in Sekunden schnelle. Es wäre möglich ein Texterzeugungssystem, zum Beispiel GPT-3, zu nutzen, um, zumindest in Teilen, das Schreiben von Artikeln für Zeitungen und Online-Nachrichtenportale zu übernehmen. Dabei sind zwei verschiedene Arten von Artikeln zu unterscheiden:

1. **Reine Nachrichtenartikel.** Damit sind Artikel gemeint dessen hauptsächlicher Zweck es ist Neuigkeiten zu vermitteln. Das können zum Beispiel Folgende Artikel sein: Verkünden des Ergebnisses eines Fußballspiels, Veränderungen am Aktienmarkt, Politische Neuigkeiten oder wichtige Weltereignisse. Wobei aber eben immer auf die reine Vermittlung von Informationen abgezielt wird.

2. **Investigative- oder Meinungsartikel.** Dies sind alle Artikel dessen Zweck über die in 1. beschriebenen Punkte hinausgehen, indem diesen eine journalistische Erforschung eines Themas beinhalten oder die eigene Meinung der Autoren vermitteln.

Diese Einteilung wurde vorgenommen, um eine bessere Abgrenzung des Themas zu schaffen, es gilt zu bedenken, dass es Artikel gibt die beiden Bereichen zugeordnet werden könnten, der Verlauf zwischen den beiden Seiten ist fließend.

Ein Texterzeugungsmodell kann grundsätzlich in beiden Fällen unterstützend angewendet werden. Allerdings wäre eine Implementierung im Fall von Investigativ- oder Meinungsartikel bedeutend schwieriger als bei Fall eins, da diese Art der Artikel deutlich komplexer ist. Aus diesem Grund soll der Fokus der hier dargestellten Anwendungsmöglichkeit im Bereich der reinen Nachrichtenartikel liegen.

Ein nicht unwesentlicher Bestandteil der Arbeit von Autoren für reine Nachrichtenartikel besteht in der heutigen Zeit darin, Pressemitteilungen oder Artikel anderer Publikationen, wie zum Beispiel die dpa (Deutsche Presse-Agentur) oder andere Zeitungen, in Artikel für das eigene Nachrichtenportal umzuschreiben. Ob dies eine aus journalistischer sich vertretbare oder sinnvolle Praktik ist, ist zwar in Frage zu stellen, soll an dieser Stelle allerdings nicht weiter behandelt werden. Es wäre möglich ein Texterzeugungsmodell zu trainieren, welches einige in Stichpunkten verfasste Informationen in einen zusammenhängenden Text umschreibt. Die Aufgabe des Autoren wäre es dann nur noch die wichtigsten Informationen aus dem Quelltext stichpunkthaft an die Software zu übergeben und daraufhin den automatisch generierten Text auf offensichtliche Fehler zu überprüfen.

Ein Beispiel, bei dem ein solches System vermutlich sehr gut funktionieren würde, sind Sportartikel. Viele Sportartikel bestehen inhaltlich nur aus dem Ergebnis und beispielhaften Nennung einiger wichtiger Ereignisse. Das Ergebnis sowie die zu nennenden Ereignisse können dem System stichpunkthaft übergeben werden. Das Modell formuliert daraufhin den Text aus.

In der Theorie wäre sogar eine noch weitere Automatisierung des Prozesses umsetzbar. Es ist möglich ein Texterzeugungsmodell auf das Zusammenfassen von Texten zu trainieren. Dementsprechend wäre es auch denkbar einem Modell beizubringen Artikel, nicht anhand von Stichpunkten, sondern anhand eines ganzen Textes als Eingabe, zu schreiben. In diesem Fall sucht sich das Modell selbst die wichtigsten Punkte aus dem Quelltext, sei es eine

3. Anwendungsmöglichkeiten

Pressemitteilung, eine dpa Meldung oder ein anderer Artikel, heraus und verfasst anhand dieser dann einen eigenen neuen Artikel. Mit einem solchen Modell wäre es möglich, den gesamten Prozess des Schreibens von Nachrichtenartikel fast vollständig zu automatisieren. Hier wäre es für den Autor, wenn man ihn dann überhaupt noch so nennen kann, dann lediglich noch nötig den Artikel auf Fehler zu überprüfen.

Ein technisches Problem bei dieser Anwendungsmöglichkeit stellt allerdings die Black Box Struktur von Maschine-Learning-Modellen dar. Insbesondere im Fall der vollständigen Automatisierung des Prozesses gibt der Autor nahezu die gesamte Kontrolle über den Erschaffungsprozess eines Artikels ab. Fällt beim Korrekturlesen auf, dass der Artikel stark von den Vorstellungen des Autors abweicht, ist es nur schwer möglich herauszufinden, woran dies liegt. Das wird unterstützt von der Tatsache, dass GPT-2 zum Beispiel, insbesondere bei längeren Texten, dazu neigt vom Thema abzuschweifen. Diese Problematik hat sich zwar mit GPT-3 etwas verbessert und natürlich gibt es auch noch andere Texterzeugungsmodelle, jedes mit anderen Eigenheiten, aber dennoch ist dies ein Problem, das immer wieder zu erkennen ist.

Eine mögliche Maßnahme gegen diesen Kontrollverlust im Erschaffungsprozess der Artikel, bei Beibehaltung einer möglichst hohen Automatisierung, ist die Verwendung von zwei voneinander unabhängigen Texterzeugungsmodellen. Das erste Modell fasst einen gegebenen Quelltext in Stichpunkten zusammen und präsentiert die Zusammenfassung dem Autor. An dieser Stelle besteht nun die Möglichkeit in den Verfassungsprozess einzugreifen, indem die Zusammenfassung des Quelltexts bearbeitet werden kann. Ist die Bearbeitung geschehen oder es ist keine Veränderung an den Stichpunkten nötig, werden diese nun von einem zweiten Texterzeugungsmodell zu einem Artikel ausformuliert. Im tatsächlichen Einsatz einer solchen Software sollte der Ablauf dieser drei Schritte flexible bleiben, zum Beispiel sollte es möglich sein den Prozess standardmäßig vollautomatisch durchlaufen zu lassen nur wenn dem Autor beim Korrekturlesen ein Problem auffällt geht dieser einen Schritt zurück, betrachtet die Zusammenfassung des ersten Modells, bearbeitet diese gegebenenfalls und führt dann nur das zweite Modell noch einmal aus. Mit dieser Methode wäre der Prozess nach wie vor stark automatisiert, allerdings ist eine größere Kontrolle über den Erstellungsprozess möglich.

Die Verwendung einer Software mit der zuvor beschriebenen Funktionalität bietet für ein Nachrichtenportal einige wichtige Vorteile.

1. Gerade in der Zeit des Internets gibt es enorm viel Konkurrenz im Bereich der Nachrichtenportale. Insbesondere wenn es um wichtige und sich schnell entwickelnde Ereignisse geht, ist es entscheidend der erste zu sein, der über ein Thema berichtet, um möglichst viele Nutzer auf die eigene Internetseite zu ziehen. Die Erzeugung eines Artikels kann mit einer solchen Software potenziell innerhalb von wenigen Sekunden geschehen. So kann eine solche Software entscheidend dazu beitragen die Reichweite der eigenen Seite sowie, durch mehr Klicks, auch Werbeeinnahmen zu erhöhen.

2. Sparen von Arbeitskraft. Aus Sicht eines Unternehmens bietet eine solche Software enormes Einsparpotential. Ist das Ergebnis der Modelle zuverlässig genug, kann jeder Mensch auch ohne jegliche Erfahrung die Software bedienen und so Nachrichtenartikel verfassen. Das bedeutet, dass für diese Aufgabe keine teuren Journalisten oder generell ausgebildete Arbeiter gebraucht werden. Außerdem werden durch die Zeitersparnis auch weniger Arbeiter für den gleichen Artikel Output benötigt. So können eine Menge Lohnkosten gespart werden.

3. Anwendungsmöglichkeiten

3. Besseres Einsetzen der Verfügbaren Arbeitskräfte. Ausgebildeten Arbeitskräften und Journalisten wird es ermöglicht, sich auf das Schreiben komplexerer und interessanterer Artikel konzentrieren.

4. Beibehalten von Authentizität. Durch die bereits heute sehr guten grammatikalischen Ergebnisse von Texterzeugungsmodellen sowie die Möglichkeit einem Modell den Stil eines Nachrichtenportals oder sogar den speziellen Stil Autors anzutrainieren, ist es möglich, nach außen weiterhin einen Authentischen Eindruck zu vermitteln.

Wie hier dargestellt wurde, könnte die Verwendung von Texterzeugungsmodellen einen enormen Mehrwert für Nachrichtenportale, insbesondere aus Unternehmenssicht bieten. Dabei sind allerdings die recht Offensichtlichen, bisher noch nicht weiter besprochenen, ethischen und wohlmöglich auch rechtlichen Probleme zu bedenken, die sich aus der Verwendung einer solchen Software ergeben könnten. Weiteres dazu ist im Kapitel vier, „Risiken“, genauer Kapitel 4.2 zu finden.

4. Risiken

Wie im vorherigen Kapitel zu sehen war, bietet die Nutzung von Texterzeugungssystemen einen großen Vorteil in einem breiten Anwendungsbereich. Allerdings können dadurch auch große Risiken und Probleme entstehen. Gerade aufgrund der immer weiter zunehmenden Leistung und Verbreitung von Texterzeugungsmodellen ist es wichtig, auch über diese potenziellen Risiken zu sprechen.

Grundlegend kann sich ein großer Teil, wenn auch nicht alle, der Risiken auf zwei Ursprünge zurückführen lassen: fahrlässige Nutzung und absichtlicher Missbrauch der Technologie. Dabei gibt es Risiken für alle Beteiligten, die Entwickler der Modelle, die direkten Nutzer der Modelle, die damit Produkte erstellen, sowie auch die Endnutzer die entsprechende, mit Texterzeugungsmodellen erstellte, Produkte oder Dienstleistungen nutzen. Die Risiken können dabei von eher insignifikanten Problemen wie zum Beispiel schlechten strategischen Entscheidungen eines Unternehmens aufgrund fehlerhafter Auswertung von Daten durch ein Texterzeugungsmodell, bis hin zu potenziell sehr schwerwiegenden Problemen, wie der massenhaften Beeinflussung von Menschen durch Desinformationskampagnen, welche mithilfe von Texterzeugungsmodellen durchgeführt werden, gehen.

Um einen sicheren Umgang mit dieser Technologie zu gewährleisten, ist es wichtig, dass alle Beteiligten, sei es bei der Erstellung eines Modells oder bei der Nutzung, verantwortungsvoll mit der Technologie umgehen. Das Problem daran ist, dass ein verantwortungsvoller Umgang voraussetzt, dass sich die Beteiligten auch über die verschiedenen Risiken bewusst sind. Auf Seite der Erstellung des Modells ist dies noch relativ wahrscheinlich. Auf der Seite der Nutzer scheint es allerdings, gerade wenn diese Technologie in der Zukunft einer breiteren Menge an Menschen zu Verfügung steht, sehr unwahrscheinlich.

Aufgrund der voranschreitenden Entwicklung und der immer größeren Verbreitung von Texterzeugungssystemen und den damit verbundenen großen Risiken, scheint es dringend notwendig, dass Gesetzgeber sich über die Möglichkeiten und potenziellen Risiken in diesem Bereich bewusst werden. Im Moment ist dieser Bereich größtenteils unreguliert, dies sollte sich, möglichst bevor große Missbrauchsfälle entsprechender Software auftreten, ändern. Sich langfristig darauf zu verlassen, dass solche Software von allen Nutzern verantwortungsvoll genutzt wird, wäre naiv. Das Problem aus Sicht der Gesetzgeber ist dabei einen Kompromiss zu finden der die weitere Forschung und Entwicklung von Texterzeugungsmodellen nicht unnötig einschränkt, schließlich bietet diese Technologie auch viele Vorteile, allerdings möglichst effektiv den Missbrauch von Texterzeugungsmodellen unterbindet. Dabei sollten bei der Verfassung entsprechender Gesetze, aufgrund der hohen Komplexität des Themas, dringend Experten des Themenbereiches in den Prozess eingebunden werden. Nur so kann gewährleistet werden, dass sinnvolle und effektive Regulierungen entstehen.

Nach dieser kurzen allgemeinen Betrachtung der Risiken von Texterzeugungsmodellen, werden in den folgenden zwei Kapiteln die möglichen Risiken aus den beiden, in Kapitel 3.1 und 3.2 vorgestellten, Anwendungsmöglichkeiten umfangreicher diskutiert.

4. Risiken

4.1 Risiken bei Anwendungsmöglichkeit 1: Automatische Quellcode-Generierung

Die Entwicklung einer Software zu automatischen Quellcode Generierung birgt einige Risiken, sowie auf Seite der Nutzer als auch auf der Seite der Entwickler der Software. Ein großes potenzielles Problem findet sich im Datensatz. Möchte man ein Texterzeugungsmodell auf die Erzeugung von Quellcode trainieren, besteht der erste Schritt darin einen Datensatz für das Training zu finden oder zu erstellen. Dabei ist es wichtig, insbesondere bei einem komplexen Thema wie Softwareentwicklung, dass der Datensatz ausreichend viele Beispiele enthält und dass diese Beispiele einen möglichst großen Aufgabenbereich abdecken. Zusätzlich wird das Ganze noch durch die Vielzahl an Programmiersprachen erschwert. Sollen mehrere Programmiersprachen unterstützt werden, müssen dementsprechend auch Beispiele für alle gewünschten Programmiersprachen, im Datensatz vorkommen. Dabei stellt sich nun die Frage: wie kommt man an einen solchen Datensatz? Grundsätzlich sind zwei verschiedene Herangehensweisen möglich. Auf der einen Seite steht die Verwendung von eigenem Quellcode. Dies bietet den Vorteil, dass es keinerlei Probleme hinsichtlich der Lizenzen gibt. Außerdem ist die Überwachung der Codequalität und vergleichbarer Merkmale deutlich einfacher. Allerdings steht diesem Ansatz ein offensichtliches Problem im Weg: Die Anzahl an Unternehmen die Zugriff auf eine ausreichend große Menge an eigenem Quellcode besitzen beschränkt sich vermutlich auf einige wenige der weltweit größten IT-Unternehmen, wie Google oder Microsoft. Für alle anderen bleibt Herangehensweise zwei: die Verwendung von öffentlich zu Verfügung stehendem Quellcode. Dabei bietet sich GitHub durch seine enorm verbreitete Nutzung als Ursprung für einen solchen Datensatz an. Hier entsteht nun allerdings aus Entwicklerseite ein rechtliches Risiko. Es ist wichtig auf die Lizenzen der einzelnen Projekte zu achten, um mögliche rechtliche Konsequenzen zu vermeiden. Die Relevanz dieses Risikos wird bei Betrachtung einiger Statistiken zur Lizenzierung von Projekten auf GitHub klar. Bei der Betrachtung der Abbildung 19 ist allerdings zu beachten, dass die Zahlen aus dem Jahr 2015 stammen und sich die prozentualen Werte seitdem etwas geändert haben können.





Abbildung 19: Darstellung der Anzahl an GitHub Repositories mit einer Lizenz sowie die Aufteilung der Verschiedenen Lizenzen (aus dem Jahr 2015) [26]

Wie zu sehen ist, waren 2015 nur etwas weniger als 20% [26] aller Repositories überhaupt unter einer speziellen Lizenz bereitgestellt worden. Alle Repositories bei denen keine genauen Lizenzangaben gemacht werden, dürfen nicht frei von anderen genutzt werden, auch wenn sie auf GitHub frei einsehbar sind. Weitere Einschränkungen ergeben sich bei der Betrachtung der Lizenztypen. Alle aufgelisteten Lizenzen erlauben die kommerzielle Nutzung des Quellcodes. Die sehr beliebten Lizenzen „GPLv2“ und „GPLv3“, die im Jahr 2015 zusammen

4. Risiken

etwa 21% aller Lizenzen auf GitHub ausmachten [26], erlauben die Nutzung des Quellcodes allerdings nur wenn die neue Software wiederum unter einer Open-Source Lizenz zur Verfügung steht. Andere Lizenzen verlangen bei Verwendung des Codes eine Quellenangabe mit Nennung des Namens des ursprünglichen Autors und einer Verlinkung. Ob das Trainieren eines Machine-Learning-Modells als echte Nutzung des Quellcodes zählt, ist nicht eindeutig geklärt. Dies zeigt auch ein generelles Problem: Viele der beliebten Lizenzen sind bereits sehr alt und wurden ohne Berücksichtigung von Machine-Learning-Modellen verfasst. Alles in allem gilt aber: auch wenn dadurch etwa 85% aller Repositories für den nutzbaren Datensatz wegfallen, ist es wichtig, die Lizenzbedingungen zu beachten, um dem rechtlichen Risiko aus dem Weg zu gehen.

Aus dem beschriebenen Risiko für die Entwickler dieser Software kann sich unter Umständen auch ein Risiko für die Nutzer ergeben. GitHub sagt zu Copilot, dass der Erzeugte Code in etwa 0,1% der Fälle ein direktes wörtliches Zitat aus dem Trainingsdatensatz enthält [25]. Ein Beispiel, in dem genau das gezeigt wird, wurde Anfang Juli 2021 vom Twitter Nutzer „Kylpeacock“ gefunden. In Abbildung 20 ist der HTML Text für eine, von Copilot generierte, „about-me“ Seite zu sehen, die scheinbar direkt der „about-me“ Seite eines gewissen „David Celis“ entstammt.



```
71 =====
72
73
74 Accept Solution
75 <div class="about-me">
76   <h2>About me</h2>
77   <p>
78     I am a software engineer from the Bay Area,
79     currently working at <a href="http://www.
80     salesforce.com">Salesforce</a>.
81   </p>
82   <p>
83     I love to learn new things and build things.
84   </p>
85   <p>
86     I have a <a href="https://github.com/
87     davidcelis">Github</a> account.
88   </p>
89   <a href="https://twitter.com/davidcelis">Follow
    me on Twitter</a>
  </div>
```

Abbildung 20: Beispiel für ein wörtliches Zitat von GitHub Copilot [27]

Eine kurze Recherche zum Thema zeigt, dass der Code für die Webseite von David Celis, die auch eine „about-me“ Seite enthält, tatsächlich auf GitHub zur Verfügung steht. Gleichzeitig wird damit das Problem allerdings etwas relativiert. Betrachtet man den Code der Seite, fällt auf, dass der Text, so wie er im Bild zu sehen ist, nicht existiert. Nicht die ganze Seite ist aus dem Trainingsquellcode zitiert, nur die Links, die zu GitHub und Twitter führen, entstammen direkt dem auf GitHub zu sehenden Code. Auf der einen Seite ist der tatsächlich zitierte Text damit, in diesem Fall, eher irrelevant. Auf der anderen Seite wurde beim Training des Texterzeugungsmodells offensichtlich der Code von David Celis verwendet ohne das bei „GitHub Copilot“ oder „OpenAI Codex“ eine Quellenangabe mit Namen und Link zu finden ist, wie es die „Creative Commons Attribution 3.0“ Lizenz, unter der der Code für die Webseite veröffentlicht wurde, eigentlich verlangt. Daraus ergibt sich ein Risiko für die Nutzer, insbesondere bei der kommerziellen Nutzung. Ein Programmierer, der mit Copilot

arbeitet kann sich nie 100%ig sicher sein ob der Code tatsächlich von der Software generiert wurde oder ob es sich um kopierten Code anderer Entwickler handelt. So können ungewollt, und ganz ohne das Wissen des Entwicklers, Plagiate entstehen. Was, insbesondere wenn die mit Copilot entwickelte Software kommerziell vertrieben werden soll, rechtliche Konsequenzen nach sich ziehen kann. Es sei allerdings gesagt, dass es möglich, ist Schritte zu unternehmen, die diesem Problem vorbeugen. So ist sich GitHub zum Beispiel dieses Problems bewusst und will in einer neueren Version von Copilot eine Funktion einbauen, die den Nutzern in der UI anzeigt, wenn Teile des Trainingsdatensatzes in einem Vorschlag enthalten sind, so dass der Nutzer entscheiden kann, wie mit der Situation umzugehen ist.

Nichtsdestotrotz stellt sich für einen Entwickler bzw. für eine Firma die Frage: wie stark vertraue ich dem Entwickler der Quellcode-Generierungs-Software, mich durch sorgfältige Behandlung dieser Probleme, vor rechtlichen Konsequenzen zu bewahren?

Nachdem nun die Rechtlichen Risiken der Nutzung aber auch der Entwicklung von Quellcode-Generierungs-Software mithilfe eines Texterzeugungsmodells dargestellt wurden, soll der Fokus im Folgenden nunmehr darauf liegen, einige andere, weniger komplexe, aber deshalb nicht weniger wichtige, Risiken entsprechender Software aufzuzeigen.

Bei der Beschreibung der Anwendungsmöglichkeit in Kapitel 3.1 wurde unter anderem die Hilfestellung bei der Erlernung von Softwareentwicklung als Vorteil genannt. Insbesondere bei einer starken Verbreitung entsprechender Assistenzsysteme kann die Anwendung dieser durch Programmieranfänger einen gegenteiligen Effekt haben. Während die Erleichterung des Einstiegs in den Bereich der Softwareentwicklung durchaus ein realistischer Effekt solcher Assistenzsysteme ist, kann die Verwendung auch dazu führen, dass sich zu stark auf dieses verlassen wird. Was im Extremfall zutreffen könnte, dass eine kommende Generation von Entwicklern auf solche Assistenzsysteme angewiesen sind. Dies würde zu zwei entscheidenden Problemen führen: Einerseits ist es möglich, dass der Wissensstand und damit die Fähigkeiten von Entwicklern, im Vergleich zu heute, geringer werden. Andererseits würde eine starke Abhängigkeit von Assistenzsystemen, den Entwicklern dieser Systeme eine enorme Macht über den Softwaremarkt geben. Ein, weniger extremes, Beispiel wie sich dieses Problem in der echten Welt zeigen könnte ist folgendes:

In der Schule, in der Ausbildung oder im Studium wird eine Programmieraufgabe gegeben. Anstatt die Aufgabe tatsächlich selbst zu lösen, wäre es, möglich ganz einfach nur die Aufgabenstellung an ein Texterzeugungsmodell als Eingabe weiterzugeben. Dieses löst dann die Aufgabe. Für einen Lehrer oder Professor, der sich die Lösungen ansieht, ist es im Nachhinein kaum noch möglich zwischen der eigenen Arbeit eines Schülers/Studenten oder der Arbeit eines Systems wie GitHub Copilot zu unterscheiden. Tatsächlich wäre genau das mit Zugriff auf GitHub Copilot bereits möglich. Syntaktisch unterscheidet sich die als Kommentar verfasste Eingabe für Copilot nur kaum von typischen Aufgabenstellungen bei Programmieraufgaben. Im Moment wird dies allerdings noch durch den beschränkten Zugriff auf solche Systeme sowie die aktuell noch beschränkte Leistung, insbesondere bei komplexeren Aufgaben, dieser verhindert.

Ein weiteres Risiko welches auch in Kapitel 3.1 bereits als Technisches Problem genannt wurde ist die Mögliche massenhafte Verbreitung von Bugs. Hat ein Texterzeugungsmodell zufällig gelernt einen bestimmten Bug zu erzeugen kann dieser, eine entsprechend große Nutzergruppe vorausgesetzt, unbemerkt über eine Vielzahl von Softwaresystemen repliziert

4. Risiken

werden. Bei einem extrem hohen Marktanteil der Quellcode-Generierungs-Software könnte dies theoretisch sogar zu weltweiten Krisensituationen führen. Etwaige Präzedenzfälle wie der Y2K-Bug fallen einem dabei ein.

Die mögliche massenhafte Verbreitung von Code wie sie eben beschrieben wurde, könnte außerdem von Hackern als Angriffsvektor verwendet werden. Entweder als gezielter Angriff auf ein spezielles Unternehmen bis hin zu einer massenhaften Einschleusung von schadhaftem Code in hunderten oder tausenden Softwaresystemen durch die Übernahme oder Infiltration eines Anbieters dieser Assistenzsysteme.

Es gilt dabei insbesondere zukünftige Assistenzsysteme zu bedenken, mit vergleichsweise einfachen Lösungen wie „GitHub Copilot“, welche, auf den Maßstab einer ganzen Softwarelösung bezogen, nur sehr kleine Codeteile erzeugen kann, ist das Risiko der Verbreitung von Bugs oder von schadhaftem Code vergleichsweise gering. Mit steigender Leistung solcher Systeme steigt allerdings auch das Risiko.

Die in diesem Kapitel dargestellten Risiken erschöpfen nicht die große Anzahl an potenziellen Risiken. Weitere, hier nicht besprochene Risiken, könnten beispielsweise allgemein sinkende Codequalität, stagnierende Neuentwicklungen durch konstante Wiederverwendung alter Konzepte oder die schon an anderen Stellen angesprochene sehr begrenzte Kontrolle über die Generierung des Outputs sein. Die hier veranschaulichten Risiken stellen nur einen kleinen Teil aller Probleme dar, zeigen jedoch gut, dass den großen Vorteilen von automatischer Quellcode-Generierung mithilfe von Texterzeugungsmodellen auch eine große Menge an Risiken und Problemen gegenübersteht. Entwickler, aber auch Nutzer, dieser Systeme müssen sich über die Risiken und Probleme bewusst sein und in der Zukunft noch deutlich mehr als zuvor passende Sicherheits- und Qualitätsstandards beachten.

4.2 Risiken bei Anwendungsmöglichkeit 2: automatische Erzeugung von Nachrichtenartikeln

Wie zuvor beschrieben, bietet die Verwendung eines Texterzeugungssystems im Prozess des Schreibens von Nachrichtenartikeln, viele Vorteile. Diesen Vorteilen stehen allerdings auch einige große Risiken gegenüber. Dabei gibt es eine relativ einfache Lösung für viele der im Folgenden dargestellten Probleme: Eine gründliche und gewissenhafte Kontrolle der Artikel durch entsprechend ausgebildetes Personal, so wie es auch bei der Beschreibung der Anwendungsmöglichkeit bereits erwähnt wurde. Das Problem daran ist, dass die Überprüfung der Artikel mit Abstand den größten Zeitanteil im Erzeugungsprozess eines Artikels einnimmt. Während das Erzeugen der Artikel, bei einer wie in Kapitel 3.2 beschriebenen Vollautomatisierung der Textgenerierung, nur wenige Sekunden dauern würde, wird für die Überprüfung, abhängig von der Länge des Artikels, ein Vielfaches der Zeit benötigt. Für Unternehmen wäre es sehr einfach, die Kontrolle der Artikel wegzulassen oder zumindest stark einzuschränken, um so die Effizienz des Prozesses, auf Kosten der Artikelqualität, um ein Vielfaches zu erhöhen. Da das Hauptziel eines Unternehmens nun einmal die Gewinnerzielung ist, scheint es wahrscheinlich, dass zumindest ein Teil der Anwender diesen Kompromiss eingehen würden. Hier besteht das hohe Risiko, dass journalistische Grundsätze auf diese Art und Weise absichtlich ignoriert werden, um eine Gewinnerhöhung zu erzielen.

Eines der ersten Probleme zeigt sich im Versuch automatisch erzeugten Artikeln eine Autorenschaft zuzuordnen. Der Autor eines Artikels trägt eine gewisse Verantwortung den Lesern gegenüber, den Artikel nach bestem Wissen wahrheitsgemäß verfasst zu haben und uneindeutige Aussagen, über die berichtet wird, durch sorgsame Wortwahl als solche darzustellen oder diese zu recherchieren, um sie bestätigen oder widerlegen zu können. Zusätzlich zur ethischen Verantwortung dem Leser gegenüber, kommt eine rechtliche Verantwortung. Ein Journalist darf, auch aus rechtlicher Sicht, nicht einfach eine unwahre Behauptung aufstellen. Das ist unter anderem in §§ 185 StGB „Beleidigung“, §§ 186 StGB „Üble Nachrede“ und §§ 187 StGB „Verleumdung“ geregelt. Geschieht dies trotzdem kann der Autor dafür rechtlich belangt werden. Was aber wenn es keinen Autor gibt, weil ein Artikel automatisch erzeugt wurde? Solange es einen zuständigen Mitarbeiter gibt, der die Artikel vor der Veröffentlichung überprüft lässt sich die Frage einfach lösen, doch wenn dies nicht der Fall ist, wird das schwieriger. Aus rechtlicher Sicht wäre vermutlich ganz einfach das Unternehmen verantwortlich. Aus ethischer Sicht ist es allerdings etwas schwieriger, natürlich wäre es auch hier einfach das Unternehmen hinter dem Nachrichtenportal verantwortlich zu machen. Es stellt sich allerdings die Frage, ob nicht zum Beispiel auch den Anbieter der Software eine gewisse Mitschuld treffen könnte.

Ein, der Frage nach der Verantwortung für die Artikel, zugrunde liegendes Problem besteht im generellen Problem Texterzeugungsmodellen ein Konzept von „Wahrheit“ beizubringen. Ein Texterzeugungsmodell, wie wir es heute kennen, kann grammatikalische Zusammenhänge verstehen und auch einfache logische Zusammenhänge in Texten erkennen oder solche Texte verfassen. Was diesen Modellen allerdings fehlt, ist ein menschliches Verständnis von Wahrheit. Was dazu führt, dass in den von GPT-3 erzeugten Texten oft willkürlich Fakten durcheinander gewürfelt werden. Das Beispiel aus Abbildung 20 im Vorherigen Kapitel kann auch hier gut als Veranschaulichung dienen. Auf der vom Modell erzeugten „about-me“ Seite wird behauptet, dass David Celis, auf dessen GitHub und Twitter Seiten verlinkt wird, ein „Softwareengineer“ aus der „Bay Area“ ist der für „Salesforce“ arbeitet. Abgesehen von dem Fakt, dass David Celis tatsächlich Softwareentwickler ist, sind diese Fakten frei erfunden. Laut seiner echten Internetseite lebt er in Portland, Oregon und

arbeitet bei „Stripe“. Auch wenn das hier benutzte Modell natürlich nicht auf das Schreiben von Nachrichtenartikeln trainiert wurde, zeigt dies gut wie willkürlich Texterzeugungsmodelle wahre Fakten mit frei erfundenen Informationen vermischen. Dies stellt, insbesondere wenn mithilfe eines solchen Modells über wichtige Ereignisse berichtet werden soll, ein sehr großes Risiko sowie für das Nachrichtenportal als auch für die Leser dar, gerade dann, wenn die Artikel vor der Veröffentlichung nicht sorgfältig kontrolliert werden.

Ein weiteres Problem, dass auf den beiden vorherigen Risiken aufbaut. Wurde auch schon bei der Beschreibung der Anwendungsmöglichkeit, allerdings als für das Unternehmen Vorteil, aufgezählt: Es ist für den Leser kaum möglich von echten Menschen geschriebene Artikel von automatisch generierten Artikeln zu unterscheiden. Aus Sicht der Unternehmen ist dies ein Vorteil, es besteht die Möglichkeit die Effizienz der Verfassung von Artikeln deutlich zu erhöhen, ohne nach außen an Authentizität zu verlieren. Dies stellt allerdings ein Risiko dar, indem die Leser sich kein eigenes Urteil über die Vertrauenswürdigkeit einer Quelle mehr bilden können.

Die bisher beschriebenen Risiken ergeben sich in erster Linie aus einer fahrlässigen Nutzung entsprechender Software. Ein besonders großes Risiko besteht allerdings im absichtlichen Missbrauch dieser Möglichkeiten. Zum Beispiel zur Verbreitung von Fehlinformationen, heute auch oft als „Fake News“ bezeichnet, oder zur Beeinflussung der Meinung von Menschen durch Umformulierung und damit ändern des Sentiments einer, eigentlich wahren, Berichterstattung. Die akute Gefahr genau dieses Problems wird in der Studie „Truth, Lies, and Automation: How Language Models Could Change Disinformation“, die im Mai 2021 vom „Center for Security and Emerging Technology“ der Universität Georgetown veröffentlicht wurde, dargestellt. Die Studie untersucht verschiedene Möglichkeiten wie GPT-3 genutzt werden kann, um Fehlinformationen zu verbreiten und generell die Meinung von Menschen zu beeinflussen. Für die hier behandelte Anwendungsmöglichkeit sind besonders die Aspekte „Narrative Ausarbeitung“ und „Narrative Manipulation“ interessant.

Die Aufgabe der „Narrativen Ausarbeitung“ wird in der Studie so beschrieben: „Schreiben eines mittel-langen Textes, der mit einer gewissen Weltansicht vereinbar ist, wenn nur eine kurze Eingabe, wie zum Beispiel eine Überschrift vorhanden ist.“ (eigene Übersetzung vom englischen Original) [28].

Währenddessen stellt „Narrative Manipulation“ folgenden Aufgabenbereich dar: „Umschreiben eines Nachrichtenartikels aus einer neuen Perspektive wobei der Unterton, die Weltansicht und das Fazit geändert werden, um ein bestimmtes Leitmotiv zu erzeugen.“ (eigene Übersetzung vom englischen Original) [28].

Betrachtet man die beiden Aufgabenbereiche, fallen schnell die starken Parallelen zu dem hier diskutierten Anwendungsfall auf. Das Fazit der Studie zum Bereich „Narrativen Ausarbeitung“ ist, dass GPT-3 hier gute Ergebnisse erzielen kann und durch Fine-Tuning eine konstant gute Leistung erzielt werden. Für den Aufgabenbereich „Narrative Manipulation“ fällt das Fazit der Studie etwas schlechter, insgesamt aber immer noch gut aus, in erste Linie wird hier hin und wieder menschliches Eingreifen benötigt.

In der Studie werden eine Vielzahl an Beispielen aufgezeigt wie ein System wie GPT-3 helfen kann, Fehlinformationen oder anders beeinflussende Texte zu erstellen. Eines der Beispiele aus dem Bereich „Narrative Manipulation“, welches besonders gut zeigt wie einfach und effektiv die Beeinflussung eines Nachrichtenartikel mithilfe von Texterzeugungsmodellen

4. Risiken

möglich ist, soll im Folgenden nun vorgestellt werden, um das Problem zu veranschaulichen. Dieses Beispiel ist besonders deshalb interessant, weil es, auch vom Arbeitsablauf her, sehr nah an der in Kapitel 3.2 beschriebenen Anwendungsmöglichkeit liegt. In dem Beispiel, welches in Abbildung 21 dargestellt ist, sind drei verschiedene Texte zu sehen. Erstens der originale Text, ein Artikel der Associated Press, welcher über die Erstürmung des US-Kapitols vom 06.01.2021 berichtet. Zweitens, eine von GPT-3 umgeschriebene Version des Artikels mit einer Pro-Trump-Ausrichtung. Drittens eine ebenfalls von GPT-3 umgeschriebene Version des Artikels welche die Ereignisse mit einer Anti-Trump-Einstellung verfasst.

ORIGINAL TEXT*

Trump doesn't ask backers to disperse after storming Capitol

President Donald Trump encouraged supporters who stormed the Capitol on Wednesday in protest of his reelection defeat to "remain peaceful," but he did not call for them to disperse.

The seat of democracy descended into chaos when protestors overwhelmed police and bulled their way into the Capitol, forcing a delay of the joint session of Congress where lawmakers were counting electoral votes that will affirm Democrat Joe Biden's White

House victory two weeks before Inauguration Day. Trump offered only a muted response to the violence as loyalists brandishing his paraphernalia clashed with police, occupied the Capitol and even stormed the Senate chamber.

Under growing pressure from allies to condemn the violence, Trump tweeted, "No violence!" adding: "Remember, WE are the Party of Law & Order - respect the Law and our great men and women in Blue."

The commander in chief did not ask supporters to vacate the area as the unrest continued.

PRO-TRUMP REWRITE

President Trump is Rightfully Disappointed

President Trump is one of the most hard-working and dedicated presidents that America has ever seen. Throughout the campaign, he promised to "drain the swamp" and end corruption. His actions are truly for the people.

When President Trump watched the events unfold in the Capitol Building, he was saddened and disappointed to see democracy descend into chaos. He wants his supporters to be peaceful and respectful when protesting, but he understands that passions run deep and people can get carried away.

President Trump has done his best to provide jobs, keep America safe, and push for better trade deals by renegotiating NAFTA. He's also done a great job at enforcing immigration laws by building a wall, cracking down on sanctuary cities, and enforcing stricter rules as to who is eligible for asylum.

The President wants his supporters to know that he's fighting for them on many fronts.

ANTI-TRUMP REWRITE

President Trump's muted response to supporters storming the Capitol is proof he's not mentally capable of leading America

President Donald Trump has failed to respond to the violence that has taken place in Washington, D.C. as his supporters stormed the Capitol building. His response has been weak and lacks any type of empathy for the people involved in the violence. One of the many things that make this disturbing is President Trump's apparent incitement of violence during his presidential campaign. He repeatedly called on his supporters to perpetrate violence against protestors at his rallies and even promised to cover their legal costs.

The president's response to his supporters storming the Capitol exposes him for who he really is: a sociopath and a danger to democracy. It's time for Republicans in Congress to finally take a stand against President Trump before he destroys America.

* Associated Press, "Trump doesn't ask backers to disperse after storming Capitol," PBS, January 6, 2021, <https://www.pbs.org/newshour/politics/gop-lawmakers-ask-trump-to-deescalate-violence>.

Abbildung 21: Beispiel für die Möglichkeit des Umschreibens von Nachrichtenartikeln mithilfe von GPT-3 unter Berücksichtigung verschiedener Weltbilder. [28]

Vor der Inhaltlichen Auswertung des in Abbildung 21 zu sehenden Beispiels, ist ein kurzer Blick auf die technische Umsetzung zu werfen. Die praktische Durchführung des Beispiels ist sehr nah an der in Kapitel 3.2 beschriebenen vollständigen Automatisierung für das Verfassen von Nachrichtenartikeln und wird in zwei Schritten durchgeführt. Zuerst wird GPT-3 eingesetzt, um den originalen Artikel zusammenzufassen, danach wird diese Zusammenfassung genutzt um im zweiten Schritt einen neuen Artikel von GPT-3 schreiben zu lassen, welcher von einer Bestimmten Meinung geprägt sein soll. [28] Durch die starke Nähe zum in Kapitel 3.2 beschriebenen Ablauf ist dieses Beispiel besonders relevant.

Beim Lesen des originalen Artikels fällt auf, dass die eigentliche Berichterstattung, gerade bei Betrachtung der sehr großen Kontroversität des Themas, relativ neutral die Eckdaten der Ereignisse wiedergibt. Dabei entsteht allerdings durch die Wortwahl an verschiedenen Stellen, zum Beispiel „[...] offered only a muted response [...]“ [28], insgesamt allerdings trotzdem ein leicht Anti-Trump ausgerichtetes Eindrücke.

Besonders interessant sind natürlich die beiden von GPT-3 verfassten Artikel. Beim Lesen beider Artikel ist zu erkennen, dass diese sowie aus grammatikalischer als auch aus logischer Sicht im Allgemeinen Sinn ergeben und so nicht ohne weiteres als von einem Texterzeugungsmodell geschrieben identifiziert werden können. Dabei ist interessant wie sich in beiden Artikeln eher subtil angedeutete, durch die Wortwahl dargestellte, Meinungen, mit sehr eindeutigen, fasst schon zu offensichtlichen Aussagen, abwechseln. So beginnt der Pro-Trump-Artikel mit der sehr eindeutigen Aussage „President Trump is one of the most hard-working [...] presidents that America has ever seen.“ [28]. Während Absatz 2 mit dem Satz „[...] he understands that passions run deep and people can get carried away.“ [28] beendet wird, welcher nach wie vor eine eindeutige Pro-Trump-Haltung darstellt, diese allerdings bedeutend subtiler wiedergibt. Das gleiche Phänomen findet sich auch im Anti-Trump-Artikel, zum Beispiel sieht die sehr deutliche Aussage „[...] before he [Trump] destroys America.“ [28] dem etwas weniger extrem formulierten ersten Absatz des Artikels gegenüber.

Eine weitere auffällige Eigenschaft, insbesondere des Pro-Trump Artikels ist, dass schon häufiger angesprochene, problematische Abschweifungen vom Thema von Texterzeugungsmodellen. Absatz drei und vier des Artikels behandeln zwar noch das Thema „Trump“ hat mit dem eigentlichen Thema „Sturm des US-Kapitols“ allerdings nichts mehr zu tun.

Insgesamt zeigt dieses Beispiel eindrucksvoll wie effektiv Texterzeugungsmodelle genutzt werden können um, auch abseits vom Schreiben reiner „Fake News“ Artikel, die Meinung von Menschen, durch das Schreiben sehr einseitiger Artikel, zu beeinflussen.

Wie in diesem Kapitel zu sehen ist, gibt es eine Vielzahl an Risiken bei der Verwendung von Texterzeugungsmodellen im Bereich der Nachrichtenartikel. Diese können sich unter anderem aus fahrlässiger Nutzung der Technologie oder auch aus dem absichtlichen Missbrauch von Texterzeugungsmodellen zum Vorantreiben einer Agenda ergeben. Der Zugriff auf entsprechende Software kann ein mächtiges Tool sein, das allerdings einen verantwortungsvollen Umgang verlangt.

5. Fazit

Am Anfang der Arbeit stand die Aufgabe einen Überblick über die verschiedenen Aspekte von Texterzeugungsmodellen zu erhalten. Dabei sind bei der Bearbeitung der verschiedenen Punkte mehrere Dinge klar geworden. Auf der einen Seite wurde schnell klar, wie komplex und umfangreich das Thema tatsächlich ist. Wie auch an verschiedenen Stellen in der Arbeit angemerkt wurde, mussten immer wieder Kompromisse eingegangen werden, um ein so umfangreiches Thema auf den Umfang einer Bachelorarbeit zu beschränken. Die theoretische Funktionsweise allein bietet, aufgrund ihrer hohen Komplexität, genug Material für eine eigenständige Arbeit. Allerdings ist auch durch den im Umfang begrenzten Teil zur theoretischen Funktionsweise ein Einblick in die Funktionsweise möglich der einen Überblick über die Abläufe in einem Modell, wie denen aus der GPT-Reihe, bietet. So konnte in dieser Arbeit zumindest ein grundlegendes Verständnis eines solchen System vermittelt werden. Auch im Kapitel zur praktischen Funktionsweise bzw. den Experimenten mit GPT-2 stellte die Komplexität ein Problem dar. Auch hier mussten verschiedenen Aspekte weggelassen werden, um den Umfang zu begrenzen. So wäre zum Beispiel eine tiefgründigere Erforschung der verschiedenen einstellbaren Variablen sinnvoll. Weiterhin wäre eine weiterführende Erforschung des aufgetretenen Problems im ersten Beispiel interessant. Wie kam es dazu, dass das größere Modell schlechtere Ergebnisse lieferte?

Die Kapitel zu den Anwendungsmöglichkeiten und Risiken stellten aus dieser Hinsicht ebenfalls ein Problem dar. Wobei hier weniger die Komplexität, sondern eher die Vielzahl an Möglichen Anwendungsfällen und Risiken es nahezu unmöglich machen die Thematik erschöpfend zu bearbeiten. Durch den Fokus auf zwei beispielhafte Anwendungsmöglichkeiten und deren Risiken konnten allerdings die Grundlegenden Möglichkeiten und Probleme der Technik dargestellt werden. Hier wäre in Zukunft eine weitere Erforschung der technischen Umsetzungen für die beschriebenen Anwendungsfälle sinnvoll. Insbesondere im Bereich der Risiken gibt es eine Vielzahl an noch zu lösenden Problemen, von denen ein Teil bereits vorgestellt wurde. Eine weitere und vor allem auch Tiefgründigere Erforschung hat hier Sinn. Möchte man Texterzeugungsmodelle in echten Produkten einsetzen ist eine Solche weitere Forschung enorm wichtig. Wie im entsprechenden Kapitel beschrieben wird gibt es ein Menge Rechtliche-, Moralisch- und Ethische Probleme, über die sich die Entwickler, die mit Texterzeugungssystemen arbeiten bewusst sein sollten. Studien wie „Truth, Lies, and Automation: How Language Models Could Change Disinformation“ die in Kapitel 4.2 vorgestellt wurde, Zeigen auf wie hoch das Potential für den Missbrauch von Texterzeugungsmodellen ist. Aus rechtlicher sich Braucht es hier dringend die Aufmerksamkeit der Gesetzgeber um Absichtlichen, aber auch unabsichtlichen, Missbrauch dieser Möglichkeiten einzugrenzen, auch wenn dies vermutlich schwierig ist. Eine Schwierigkeit bei der Diskussion der Risiken stellte außerdem gerade die Diskussion der ethischen- und moralischen Probleme dar. Aufgrund der Beschaffenheit dieser Probleme fließt bei einer solchen Diskussion immer auch die eigene Meinung des Autors mit ein. Es galt dabei allerdings die Risiken möglichst Objektiv und Fair darzustellen.

Weitergehende Untersuchungen zum Thema Texterzeugungsmodelle sind in verschiedenen Richtungen möglich. Neben bereits genannten Möglichkeiten der weiteren Erforschung des Themas, wäre auch die spezifische Betrachtung anderer Texterzeugungsmodelle interessant. Der Fokus bei der Praktischen Erforschung lag in dieser Arbeit auf GPT-2, allerdings wäre gerade die Arbeit mit dem Nachfolger, GPT-3, interessant um vergleiche zwischen den Modellen ziehen zu können. Auch die Erforschung gänzlich andere Modellreihen wie BERT

und seine vielen Ableger wäre sinnvoll um auch hier vergleiche zwischen den Modellen ziehen zu können. Eine weitere Möglichkeit die Forschung fortzusetzen wäre die genauere Erforschung der technischen Details und die genaue Erforschung der Umsetzungen, auch aus Mathematischer Sicht. Mit einem entsprechenden tieferen Verständnis der Technologie wäre es vielleicht sogar möglich eigene Ansätze zur Verbesserung von Texterzeugungsmodellen zu entwerfen. Aufgrund der Hohen Komplexität dieses Forschungsbereichs wäre dazu allerdings eine sehr umfangreiche weitere Forschung notwendig.

Alles in allem konnte das ursprünglich gesetzte Ziel, einen Überblick über die verschiedenen Aspekte von Texterzeugungsmodellen zu geben, erreicht werden. Wobei eben die verschiedenen angesprochenen Einschränkungen, die zu einer umfassenden Untersuchung des Themas gehören würden, beachtet werden müssen. Viele der angesprochenen Themen bietet Raum für eine weitere umfangreiche Erforschung dieser, nicht zuletzt, weil Texterzeugungsmodelle immer weiterentwickelt werden und immer mehr an Leistung gewinnen. Gerade aufgrund der zunehmenden Möglichkeiten dieser Technologie und des breiten Anwendungsfelds werden entsprechende Modelle in immer mehr in echte Produkte integriert werden. Dies macht die weiter Forschung auf dem Gebiet wichtig und interessant.

Abbildungsverzeichnis

Abbildung 1: Vereinfachte Darstellung eines Künstlichen neuronalen Netzes [1]	4
Abbildung 2: Architektur des Transformer Modells [14]	10
Abbildung 3: Beispielhafte Trainings- und Test-fehlerrate eines neuronalen Netzes mit 20 Schichten im Vergleich mit 56 Schichten auf dem CIFAR-10 Datensatz [15].....	11
Abbildung 4: Scaled Dot-Product Attention [14].....	12
Abbildung 5: Multi-Head Attention Schicht [14]	13
Abbildung 6: Aufbau des Transformer Decoders im Fall von GPT [17]	15
Abbildung 7:Inputs für das Fine-Tuning auf vier verschiedene Aufgaben [17]	16
Abbildung 8: Code für das Finetuning von GPT-2 mithilfe von gpt-2-simple	19
Abbildung 9: Beispielhafte Formatierung einer einzelnen Aufgabe	22
Abbildung 10: Kontext für die Fragen des verstehenden Lesens. Quelle: [20].....	23
Abbildung 11: Vergleich der Antworten beider Modelle auf die Frage: „When was pluto discovered?“	23
Abbildung 12: Vergleich der Antworten beider Modelle auf die Frage: „When did pluto stop being a planet?“	24
Abbildung 13: Vergleich der Ergebnisse zu der Frage: „How many planets are in the solar system?“	25
Abbildung 14: Kontext für den zusätzlichen Test zur Überprüfung der Theorie. Quelle: Auszug aus dem Wikipedia Eintrag zu „The Expanse“ [21] (eigene Übersetzung ins englische)	26
Abbildung 15: Vergleich beider Modelle anhand eines anderen Textes	26
Abbildung 16: Beispielaufgabe für das Finetuning zum Lösen von Gleichungen	28
Abbildung 17: Vergleich der Lösungen für die Gleichungsaufgaben	29
Abbildung 18: Quellcode Beispiel von „GitHub Copilot“ [22]	37
Abbildung 19: Darstellung der Anzahl an GitHub Repositories mit einer Lizenz sowie die Aufteilung der Verschiedenen Lizenzen (aus dem Jahr 2015) [23]	44
Abbildung 20: Beispiel für ein Wörtliches Zitat von GitHub Copilot [24].....	45
Abbildung 21: Beispiel für die Möglichkeit des Umschreibens von Nachrichtenartikeln mithilfe von GPT-3 unter Berücksichtigung verschiedener Weltbilder. [25]	50

Tabellenverzeichnis

Tabelle 1: 30 von GPT-2 beantwortete Fragen, sortiert nach der von GPT-2 berechneten Wahrscheinlichkeit für die gegebenen Antworten. Quelle: [16]	17
Tabelle 2: Aufgaben und ihre Lösungen für die Tests zum Lösen von Gleichungen	29

Literaturverzeichnis

- [1] V. Wittpahl, „Künstliche Intelligenz,“ Berlin, Heidelberg, Springer Vieweg, 2019, pp. 24-33.
- [2] I. Sutskever, O. Vinyals und Q. V. Le, „Sequence to Sequence Learning with Neural Networks,“ 10 09 2014. [Online]. Available: <https://arxiv.org/abs/1409.3215>. [Zugriff am 31 08 2021].
- [3] D. Gershgorn, „Popular Science,“ 12 12 2015. [Online]. Available: <https://www.popsci.com/new-openai-artificial-intelligence-group-formed-by-elon-musk-peter-thiel-and-more/>. [Zugriff am 28 06 2021].
- [4] J. Vincent, „The Verge,“ 21 02 2018. [Online]. Available: <https://www.theverge.com/2018/2/21/17036214/elon-musk-openai-ai-safety-leaves-board>. [Zugriff am 28 06 2021].
- [5] „OpenAI,“ [Online]. Available: <https://openai.com/about/>. [Zugriff am 28 06 2021].
- [6] „OpenAI,“ [Online]. Available: <https://openai.com/chapter/>. [Zugriff am 28 06 2021].
- [7] G. Brockman und J. Schulman, „OpenAI,“ 27 04 2016. [Online]. Available: <https://openai.com/blog/openai-gym-beta/>. [Zugriff am 28 06 2021].
- [8] „openAI,“ [Online]. Available: <https://openai.com/projects/five/>. [Zugriff am 28 06 2021].
- [9] A. Radford, „OpenAI,“ 11 06 2018. [Online]. Available: <https://openai.com/blog/language-unsupervised/>. [Zugriff am 30 06 2021].
- [10] A. Radford, J. Wu, D. Amodei, D. Amodei, J. Clark, M. Brundage und I. Sutskever, „Better Language Models and Their Implications,“ 14 02 2019. [Online]. Available: <https://openai.com/blog/better-language-models/>. [Zugriff am 30 06 2021].
- [11] I. Solaiman, J. Clark und M. Brundage, „GPT-2: 1.5B Release,“ 05 11 2019. [Online]. Available: <https://openai.com/blog/gpt-2-1-5b-release/>. [Zugriff am 30 06 2021].
- [12] T. B. Brown, . B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever und D. Amodei, „Language Models are Few-Shot Learners,“ 26 05 2020. [Online]. Available: <https://arxiv.org/abs/2005.14165>. [Zugriff am 01 07 2021].
- [13] GPT-3, „The Guardian,“ [Online]. Available: <https://www.theguardian.com/commentisfree/2020/sep/08/robot-wrote-this-article-gpt-3>. [Zugriff am 31 05 2021].
- [14] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser und I. Polosukhin, „Attention Is All You Need,“ 12 06 2017. [Online]. Available: <https://arxiv.org/abs/1706.03762>. [Zugriff am 05 07 2021].

- [15] K. He, X. Zhang, S. Ren und J. Sun, „Deep Residual Learning for Image Recognition,“ 10 12 2015. [Online]. Available: <https://arxiv.org/pdf/1512.03385.pdf>. [Zugriff am 10 07 2021].
- [16] P. J. Liu, M. Saleh, E. Pot, B. Goodrich, R. Sepassi, Ł. Kaiser und N. Shazeer, „Generating wikipedia by summarizing long sequences,“ 30 01 2018. [Online]. Available: <https://arxiv.org/pdf/1801.10198.pdf>. [Zugriff am 12 07 2021].
- [17] A. Radford, K. Narasimhan, T. Salimans und I. Sutskever, „Improving Language Understanding by Generative Pre-Training,“ 11 06 2018. [Online]. Available: https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf. [Zugriff am 12 07 2021].
- [18] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei und I. Sutskever, „Language Models are Unsupervised Multitask Learners,“ 14 02 2019. [Online]. Available: https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf. [Zugriff am 13 07 2021].
- [19] M. WWoof, „Train a GPT-2 Text-Generating Model w/ GPU For Free,“ 14 02 2021. [Online]. Available: <https://colab.research.google.com/drive/1VLG8e7YSEwypxU-noRNhsv5dW4NfTGce>. [Zugriff am 17 09 2021].
- [20] C. Reams, „Question Answering with GPT-2,“ 25 01 2020. [Online]. Available: <https://medium.com/analytics-vidhya/an-ai-that-does-your-homework-e5fa40c43d17>. [Zugriff am 26 07 2021].
- [21] „Descending into ML: Training and Loss,“ Machine Learning Crash Course, [Online]. Available: <https://developers.google.com/machine-learning/crash-course/descending-into-ml/training-and-loss>. [Zugriff am 17 09 2021].
- [22] R. R. Britt, „Solar System Planets: Order of the 8 (or 9) Planets,“ 01 05 2021. [Online]. Available: <https://www.space.com/16080-solar-system-planets.html>. [Zugriff am 26 07 2021].
- [23] „The Expanse (Fernsehserie),“ [Online]. Available: [https://de.wikipedia.org/wiki/The_Expanse_\(Fernsehserie\)](https://de.wikipedia.org/wiki/The_Expanse_(Fernsehserie)). [Zugriff am 27 07 2021].
- [24] „overfitting,“ Lexico, [Online]. Available: <https://www.lexico.com/definition/overfitting>. [Zugriff am 17 09 2021].
- [25] „GitHub Copilot,“ [Online]. Available: <https://copilot.github.com/>. [Zugriff am 24 08 2021].
- [26] B. Balter, „Open source license usage on GitHub.com,“ The GitHub Blog, 09 03 2015. [Online]. Available: <https://github.blog/2015-03-09-open-source-license-usage-on-github-com/>. [Zugriff am 28 08 2021].
- [27] @kylpeacock, „Congrats @davidcelis, you get a shout out if #GitHubCopilot tries to generate an "About me page",“ twitter, 02 07 2021. [Online]. Available: <https://twitter.com/kylpeacock/status/1410749018183933952>. [Zugriff am 28 08 2021].
- [28] B. Buchanan, M. Musser, A. Lohn und K. Sedova, „Truth, Lies, and Automation: How Language Models Could Change Disinformation,“ 05 2021. [Online]. Available: <https://cset.georgetown.edu/publication/truth-lies-and-automation/>. [Zugriff am 30 08 2021].

